

AI/BigData 인텐시브 과정

강사장철원

Section 0
코스 소개

DAY1	DAY2	DAY3	DAY4	DAY5
데이터 분석을 위한 기초 수학			데이터 집계 및 시각화	
DAY6	DAY7	DAY8	DAY9	DAY10
	미니 프로젝트	확률분포, AB테스트		
DAY11	DAY12	DAY13	DAY14	DAY15
머신러닝				
DAY16	DAY17	DAY18	DAY19	DAY20
딥러닝		파이널 프로젝트		

반한x
원래도쓰기..
부분점수

중간시험
주제명

□ 확률분포


□ 이산형 확률분포

□ 연속형 확률분포

AI/BigData 인텐시브 과정

Section 1. 확률 분포

Section 1-1. 확률 분포의 개념




히스토그램

따라가도록 EDA

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간

50, 60, 65, 71, 73, 78, 81, 84, 89, 94



구간이 달라지면?


히스토그램

seaborn에서
bins 조절

다르게보임
✓

유저별 게임 플레이 시간

50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

표준편차

6. 너무 작아도 문제. 보통 10에서 작으면 좀 걱긴 하지만(?)

표준편차 > 평균 이면 표준편차가 크다고 판단할

In [9]:

```
1 df.describe()
```

Out [9]:

데이터 행(row) 수

평균

표준편차

최소값

Q1

중앙값, Q2

Q3

최대값

	ACHIEVEMENT	ABILITY	ATTITUDE
count	1000.000000	1000.000000	1000.000000
mean	66.089000	69.169000	68.054000
std	15.16308	14.600192	15.195657
min	0.000000	17.000000	10.000000
25%	57.000000	59.000000	57.750000
50%	66.000000	70.000000	69.000000
75%	77.000000	79.000000	79.000000
max	100.000000	100.000000	100.000000

분산은 평균과
평균에서
표준편차승

히스토그램


* 데이터 개수가 많아지면 정규분포를 따른다. (X)

→ 독립성.


정규분포를 정정하고 있어서

정규분포

평균. 중앙값이 거의? 똑같은 특징.




히스토그램



히스토그램

(예) 마늘 가격

비타분포




히스토그램

In [6]:

```
1 import seaborn as sns
2
3 sns.histplot(data=df, x="ACHIEVEMENT")
```


Out[6]: <AxesSubplot:xlabel='ACHIEVEMENT', ylabel='Count'>



확률 분포(probability distribution)

확률 분포(probability distribution): 확률 변수가 특정한 값을 가질 확률을 나타내는 함수


확률 분포(probability distribution)의 종류



확률 질량 함수(probability mass function, pmf)

이산 확률 변수에서 특정 값에 대한 확률을 나타내는 함수

X 적과 값의 개수를 셀 수 있다



확률변수

$$P(X=x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$

확률 상수

각사건값

연속 확률 변수에서 특정 구간에 포함될 확률을 나타내는 함수

확률 밀도 함수(probability density function, pdf)

5분에 한대씩 오는 버스가 있을 때,
철수가 정류장에서 버스가 올때 까지 기다리는 시간 x
단위: 분

$$f_X(x) = \frac{1}{5}, \quad 0 \leq x \leq 5$$


철수가 버스 도착까지 0분에서 2분사이로 기다릴 확률

정답으로 확률구함

$$P(0 \leq X \leq 2) = \int_0^2 \frac{1}{5} dx$$



$$P(2 \leq x \leq 2) = 0$$

(면적이 0)



확률 밀도 함수(probability density function, pdf)

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx$$



누적분포함수(cumulative distribution function) - 이산형

주어진 확률 변수가 특정 값보다 작거나 같을 확률

$$F_X(x) = P(X \leq x) = \sum_{X \leq x} P(X = x)$$

시201


(ex) 주사위문제

$$P(X \leq 0.4) = 0 \quad P(X \leq 0.9) = 0$$

$$P(X \leq 1) = P(X = 1) = \frac{1}{6}$$

$$P(X \leq 1.8) = \frac{1}{6}$$

$$P(X \leq 2) = P(X = 1) + P(X = 2) = \frac{2}{6} = \frac{1}{3}$$



CDF

누적분포함수(cumulative distribution function) - 연속형

주어진 확률 변수가 특정 값보다 작거나 같을 확률

(0x) 부품의 수명

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(u) du$$

정확.

$$P(X > 10000) = 1 - P(X \leq 10000) \\ = 1 - \text{CDF}$$


CDF
 $F_X(x)$

이름함곡선

1

0

X



기대값(Expected Value)

확률 변수의 평균적인 값 *평균 개념.*
 기대값은 확률 질량 함수나 확률 밀도 함수로 정의됨

이산 확률 변수의 기대값

$$E(X) = \sum_x x \cdot P(X = x)$$

$$1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + \dots + 6 \cdot \frac{1}{6}$$

선형대수에서 내적개념

연속 확률 변수의 기대값

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

분산(Variance)

이산 확률 변수의 분산

$$Var(X) = E[(X - \mu)^2] = \sum_x (x - \mu)^2 P(X = x)$$

연속 확률 변수의 분산

$$Var(X) = E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x) dx$$

분산(Variance)

기댓값에 대한

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2 - 2X\mu + \mu^2]$$

$$= E(X^2) - 2\mu E(X) + \mu^2$$

$$= E(X^2) - 2\mu^2 + \mu^2$$

$$= E(X^2) - \mu^2$$

기대값(Expected Value) - 이산형 예제

주사위를 한 번 던질 때 나오는 수를 확률 변수 X 라고 했을 때 X 의 기대값 구하기

$$P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$

$$E(X) = \sum_{x=1}^6 x \cdot P(X = x) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = 3.5$$

분산(Variance) - 이산형 예제

주사위를 한 번 던질 때 나오는 수를 확률 변수 X 라고 했을 때 X 의 분산

$$P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$

$$\text{Var}(X) = E[(X - \mu)^2] = \sum_{x=1}^6 (x - \mu)^2 P(X = x) = \sum_{x=1}^6 (x - 3.5)^2 \cdot \frac{1}{6} = 2.91$$

기대값(Expected Value) - 연속형 예제

확률 변수 X 의 기대값 구하기

정답은 기형안나옴

$$f_X(x) = \frac{1}{10}, \quad 0 \leq x \leq 10$$

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx = \int_0^{10} x \cdot \frac{1}{10} dx = \frac{1}{10} \int_0^{10} x dx = \frac{1}{10} \left[\frac{x^2}{2} \right]_0^{10} = \frac{1}{10} \cdot \frac{100}{2} = 5$$

분산(Variance) - 연속형 예제

확률 변수 X 의 분산

$$f_X(x) = \frac{1}{10}, \quad 0 \leq x \leq 10$$

$$\begin{aligned} Var(X) &= \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x) dx = \frac{1}{10} \int_0^{10} (x - 5)^2 dx = \frac{1}{10} \cdot \frac{1}{3} [(x - 5)^3]_0^{10} \\ &= \frac{1}{10} \cdot \frac{1}{3} [(10 - 5)^3 - (0 - 5)^3] = \frac{1}{30} (125 + 125) = \frac{250}{30} = 8.33 \end{aligned}$$

AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-1. 균일 분포

<이산형 확률분포 시작>

$P(X=x)$
데이터가 있는 경우

$P(X)$
데이터가 없는 경우

「 회사에서 언제 출근할까? 」

조건부 확률에서 사전 확률

(ex) 데이터 없는 상태에서
플드기의 흥행 확률?

$$P(X) = \frac{1}{2} \cdot (\text{플드기 실패 확률})$$

균일 분포(uniform distribution)

균일 분포(uniform distribution)

: 확률 변수가 특정 값을 가질 확률이 모두 동일한 분포

$$P(X=x) = \frac{1}{n}$$

→ 베이지안에서 사전 확률을
구할 때 균일분포를 활용함

정확하지 않으나 균일분포 사용


Ex) 동전을 던졌을 때, 앞면, 뒷면이 각각 나올 확률

$$P(X=x) = \frac{1}{2}$$

Ex) 주사위를 던졌을 때, 1, 2, 3, 4, 5, 6이 각각 나올 확률 $P(X=x) = \frac{1}{6}$

균일 분포(uniform distribution)


표준세주개위 4면?
 $X \sim U(1, 8)$
 $P(X=7) = \frac{1}{8}$



확률변수 x 는 어떤분포를 따르나.
 $X \sim U[1, 6]$ uniform distribution
최소값, 최대값
(분포의 특성을 나타내는 수)
 $P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$

$P(X = 1) = \frac{1}{6}$	$P(X = 4) = \frac{1}{6}$
$P(X = 2) = \frac{1}{6}$	$P(X = 5) = \frac{1}{6}$
$P(X = 3) = \frac{1}{6}$	$P(X = 6) = \frac{1}{6}$

균일 분포(uniform distribution)



$$X \sim U(1, N)$$


$$P(X = x) = \frac{1}{N}, \quad x = 1, 2, \dots, N$$

$$E(X) = \frac{N+1}{2}$$

참만하기
(개방?)

$$Var(X) = \frac{(N+1)(N-1)}{12}$$

균일 분포(uniform distribution)




$$X \sim U(1, 5)$$

$$P(X = x) = \frac{1}{5}, \quad x = 1, 2, \dots, 5$$

$$E(X) = \frac{5 + 1}{2}$$

$$Var(X) = \frac{(5 + 1)(5 - 1)}{12}$$

균일 분포(uniform distribution)



1박이 10이아는정역 일반화

$$X \sim U(a, b)$$

$$P(X = x) = \frac{1}{b - a + 1}, \quad x = a, a + 1, \dots, b$$

$$E(X) = \frac{a + b}{2}$$

$$\text{Var}(X) = \frac{(b - a + 1)^2 - 1}{12}$$

균일 분포(uniform distribution)


```
In [5]: 1 import numpy as np
        2 import pandas as pd
        3 import matplotlib.pyplot as plt
```

```
In [20]: 1 x = np.random.randint(low=1, high=6, size=100)
```

```
In [21]: 1 x
```

```
Out [21]: array([2, 2, 4, 5, 5, 2, 1, 4, 1, 3, 4, 4, 5, 2, 1, 2, 1, 5, 2, 3, 5, 1,
                1, 4, 1, 5, 2, 3, 5, 4, 1, 4, 2, 2, 2, 4, 5, 5, 5, 4, 3, 2, 3, 1,
                2, 2, 4, 4, 1, 5, 3, 4, 5, 2, 5, 4, 1, 4, 4, 4, 3, 5, 5, 1, 3, 1,
                4, 3, 2, 1, 5, 4, 4, 5, 3, 4, 5, 5, 5, 4, 3, 5, 1, 1, 1, 4, 1, 1,
                5, 4, 5, 1, 4, 4, 5, 5, 5, 2, 5, 3])
```

```
In [26]: 1 plt.hist(x, bins=10)
        2 plt.show()
```




6은 100번이 안됨 (high-1까지 포함됨)

size=100번
최대값 5까지 나올 수 있음

균일 분포(uniform distribution)

```
In [27]: 1 x = np.random.randint(low=1, high=6, size=10000)
```

```
In [28]: 1 plt.hist(x, bins=10)  
2 plt.show()
```



이 코드는 10개의
평행하게 균등

AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-2. 베르누이 분포

베르누이 분포(Bernoulli distribution)

실패 성공 (관심이 있는 일이 발생하면 1)

(ex) 불량 1
정상 0

: 확률 변수가 가질 수 있는 값이 0 혹은 1

: 이 때 0 혹은 1이라는 말은 실패면 0, 성공이면 1이라고 할 수 있음

: 성공 확률이 p 이면 실패 확률은 $1-p$

: 한 번 시행했을 때의 성공 횟수 $\Rightarrow$ 최댓값이 1

: 시행을 한 번만 하므로 베르누이 시행이라고도 함
= 베르누이분포

Ex) 동전을 던졌을 때 앞면이 나오는 경우가 성공이라고 할 경우, 성공할 확률은?


$\frac{1}{2}$

Ex) 주사위를 던졌을 때 6이 나오는 경우가 성공이라고 할 경우, 성공할 확률은?

$\frac{1}{6}$

$P(X=x) = \begin{cases} p, & x=1 \\ 1-p, & x=0 \end{cases}$
 이렇게 쓰는 이유?
 가능하지만 1줄로 쓰기
 좋아함.

베르누이 분포(Bernoulli distribution)




$P(X=0) = p^0 \cdot (1-p)^1 = 1-p$
 (pmf) $P(X=1) = p^1 \cdot (1-p)^0 = p$
 $P(X=x) = p^x (1-p)^{1-x}, \quad x = 0, 1$

$E(X) = p$
 1번 시행하는데
 기대값 p

$Var(X) = p(1-p)$

베르누이 분포(Bernoulli distribution)



$$p = 0.6$$

$$P(X = x) = 0.6^x (1 - 0.6)^{1-x}, \quad x = 0, 1$$

$$E(X) = 0.6$$

$$\text{Var}(X) = 0.6(1 - 0.6) = 0.24$$

주사위 던지는 실험을 100번 하고 싶다



① 번 시행하는 것이 때문에 1로 설정

अभि
ष्ट


Number of Children	Frequency
0	72
1	28

→ 배려하기로는 비용을 조정할 수 있다

베르누이 분포(Bernoulli distribution)

```
In [33]: 1 x = np.random.binomial(n=1, p=1/3, size=1000)
```

```
In [34]: 1 plt.hist(x, bins=3)  
2 plt.show()
```



사미즈를 두려면 $\frac{2}{3}$. $\frac{1}{3}$ 에 두렴

feature 히스토그램 시작하시 0,1을 가지는 변수가
있다면 베르누이 / 원일분포를 따르는지 봐보기

AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-3. 이항 분포

이항 분포(binomial distribution)

- : 이항 분포는 독립적으로 베르누이 시행을 n 번 한 경우의 총 성공 횟수
- : 확률 변수가 가질 수 있는 값은 0부터 n 까지 *n이 전부다 성공. 0이 전부다 실패*
- : 0은 모든 시행이 실패한 경우, n 은 모든 시행이 성공한 경우
- : 각 시행의 성공 확률이 p 이면 실패 확률은 $1-p$

이항 분포(binomial distribution)


이항 분포(binomial distribution)의 예

Ex) 동전을 던졌을 때 앞면이 나오는 경우가 성공이라고 할 경우,
다섯 번 던졌을 때의 성공 횟수는?

Ex) 주사위를 던졌을 때 6이 나오는 경우가 성공이라고 할 경우,
10번 던졌을 때의 성공 횟수는?

이항 분포(binomial distribution)

$$\begin{pmatrix} 000xx \\ 00xx0 \\ 0xx00 \\ \vdots \end{pmatrix} 5C2$$



$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, \quad x = 0, 1, \dots, n$$

②
① 원리 확인

$$\binom{n}{x} = \frac{n!}{x! (n-x)!} \quad nCd$$

$$E(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

이항 분포(binomial distribution)

In [2]: 1 x = np.random.binomial(n=10, p=1/3, size=100)

실험을 100번


In [3]: 1 x

10번중 3번성공.
(실험 1번)

1번의 실험 내에서
시행 10번.

Out [3]: array([3, 3, 5, 6, 4, 4, 4, 2, 4, 4, 3, 5, 3, 1, 3, 4, 2, 2, 3, 5, 5, 3,
4, 5, 2, 4, 4, 3, 3, 2, 3, 4, 5, 1, 2, 4, 1, 4, 3, 2, 5, 2, 4, 1,
6, 3, 4, 4, 3, 3, 2, 4, 4, 3, 1, 5, 1, 2, 4, 3, 4, 3, 1, 4, 2, 2,
3, 4, 5, 5, 2, 3, 7, 4, 3, 4, 2, 5, 4, 3, 6, 1, 2, 6, 3, 2, 1, 3,
3, 4, 3, 2, 2, 2, 4, 4, 3, 4, 1, 5])

In [8]: 1 plt.hist(x, bins=30)
2 plt.show()



베르누이 실험을 여러번 반복해서 얻어낸 것이다.

베르누이 실험은 이항분포의 특수한 하나의 케이스이다.

다시 실험을 해도 똑같은

베르누이 실험을 하는 경우

$n=10$

- 첫번째 실험 0000000000 (10번실험. 0번성공)
- 두번째 실험 1111100000 (10번실험. 2번성공)
- 세번째 실험 0000011111 (10번실험. 3번성공)


⋮

- 100번째 실험.
- size=100

이항 분포(binomial distribution)

```
In [9]: 1 x2 = np.random.binomial(n=10, p=1/3, size=1000)
```

```
In [12]: 1 plt.hist(x2, bins=30)  
2 plt.show()
```



$p = \frac{1}{3}$ 이기 때문에 약간 왼쪽으로 치우쳐 있음.
대칭을 만들고 싶다면 $p = \frac{1}{2}$ 로 세팅

AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-4. 포아송 분포

포아송 분포(poisson distribution)

우리가 정한 기원시간

(시험예제)

Q 단위시간동안 이벤트가 몇 번 발생시 확률 분포이냐?

A. 포아송분포

: 단위 시간 동안 관심있는 이벤트가 몇 번 발생할 것인지를 나타내는 분포

: 확률 변수가 가질 수 있는 값은 0부터 무한대까지

1시간동안 불량이 3건 발생할 확률.

Ex) 어떤 게임에서 1분 동안 결제하는 유저 수가 3명 이상일 확률은?

Ex) 인터넷 쇼핑몰에서 1시간 동안 구매 취소하는 구매자 수가 5명 이상일 확률?

포아송 분포(poisson distribution)

단위시간당 부품이 3개 이상
고장날 확률

$$P(X \geq 3) = P(X=3) + P(X=4) + \dots - \infty$$

$$= 1 - P(X < 3)$$

$$= 1 - P(X \leq 2)$$

누적분포함수 활용

$$= (1 - \{P(X=0) + P(X=1) + P(X=2)\})$$

PMF

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, \dots$$

↓
뒤가 영점으로
약터 00

$$e^{\lambda} = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$$

$E(X) = \lambda$

$Var(X) = \lambda$

기댓값과
분산이 같은
유일한 분포

단위시간당 3개가 고장난다고
알려져 있을 때, ($\lambda=3$)

Q. 단위시간 동안 고장난 부품이 2개를 찾을

$$A. P(X=2) = \frac{e^{-\lambda} \lambda^2}{2!}$$

$$= \frac{e^{-3} \cdot 3^2}{2} = \frac{e^{-3} \cdot 9}{2}$$

⇒ 가는 단위시간 동안


이벤트가 몇번 발생할지가

알려져있어야함. (문제조건에 추가되어있어야함)


포아송 분포(poisson distribution)

왼쪽부터 오른쪽에서

$$\lambda = 5$$



$$\lambda = 15$$




포아송 분포(poisson distribution)

```
In [36]: 1 x = np.random.poisson(lam=2, size=100)
```

```
In [37]: 1 x
```

```
Out[37]: array([0, 1, 2, 2, 0, 1, 5, 2, 3, 3, 3, 2, 1, 2, 5, 3, 3, 2, 3, 0, 3, 1,
                2, 1, 2, 4, 0, 1, 4, 3, 2, 4, 1, 1, 2, 3, 3, 1, 2, 1, 2, 0, 1, 1,
                3, 3, 2, 2, 2, 1, 2, 1, 3, 4, 3, 2, 3, 1, 1, 1, 2, 1, 1, 3, 0, 1,
                1, 2, 0, 0, 2, 1, 2, 1, 2, 2, 2, 2, 1, 2, 1, 1, 7, 1, 1, 3, 4, 1,
                2, 1, 3, 4, 5, 0, 0, 3, 3, 2, 0, 5])
```

```
In [38]: 1 plt.hist(x, bins=30)
         2 plt.show()
```



나름대로 있는 지의 범위(가 무한대
C(이항분포와 다름))


포아송 분포(poisson distribution)

```
In [42]: 1 x = np.random.poisson(lam=2, size=10000)
```

```
In [43]: 1 x
```

```
Out[43]: array([2, 1, 2, ..., 1, 5, 0])
```

```
In [44]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



10000 번 중 8이 20개 정도임 .

* feature의 데이터 생성시
범위가 정해져있다면 이항분포 생성.
이제이면 포아송

AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-5. 기하분포

기하 분포(geometric distribution)

(ex) 게임팩 강하능거
망에뜨는거 나올때까지

: 처음 성공할 때까지 시도한 횟수(X)의 분포


: 처음 성공할 때까지의 실패 횟수(Y)의 분포

$$Y = X - 1$$

왜냐
✓
→ 마지막 성공으로 끝내기 때문에
이런 식이 나오는것

$$X = 7$$

처음 성공 할 때까지의 시도 횟수



$$Y = 6$$

처음 성공 할 때까지의 실패 횟수 ($Y = X - 1$)

기하 분포(geometric distribution)

실패 성공
x x x x x ... 0
기-1번 1번

$\Rightarrow (1-p)^{기-1} \cdot p$

$\left[\begin{array}{l} xxxx0 \rightarrow d=5 \\ xx x0x \rightarrow d=4 \\ xx0xx \rightarrow d=3 \\ x0xxx \rightarrow d=2 \\ 0xxxx \rightarrow d=1 \end{array} \right.$

$X =$ 처음 성공할때까지의 시도 횟수

$$P(X = x) = p(1 - p)^{x-1}, \quad x = 1, 2, \dots$$

∞ 횟수
1부터 시작 !!!



1번 시도해야함

$$E(X) = \frac{1}{p}$$

$$Var(X) = \frac{1-p}{p^2}$$

기하 분포(geometric distribution)

→ 지수분포랑 비슷하게 생김




기하 분포(geometric distribution)

```
In [47]: 1 x = np.random.geometric(p=1/3, size=100)
```

```
In [48]: 1 x
```

```
Out[48]: array([ 1,  1,  3,  1,  2,  8,  6,  4,  2,  6,  4,  8,  2,  1,  3,
  5,  1,  1, 11,  2,  2,  1,  2,  1,  1,  2,  4,  1,  2,  6,  4,  1,
  1,  1,  1,  1,  1,  6,  4,  2,  4,  3,  1,  4,  1,  2,  1,  3,  1,
  5,  5,  5,  7,  2,  6,  5,  1,  2,  2,  2,  1,  6,  1,  1,  1,  3,
  3,  5,  3,  2,  1,  3,  1,  2,  1,  1,  1,  3,  2,  1,  2,  1,  1,
  3,  2,  1,  1,  1,  3,  2,  2,  1,  2,  4,  1,  5,  5,  3])
```

```
In [49]: 1 plt.hist(x, bins=30)
2 plt.show()
```




$$\begin{aligned} P(X=1) &= \frac{1}{3} \quad (\text{성공}) \\ P(X=2) &= \frac{2}{3} \cdot \frac{1}{3} = \frac{2}{9} \\ P(X=3) &= \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{1}{3} = \frac{4}{27} \end{aligned}$$

Q. 초성자의 행운을 설명할 수 있는 분포?

기하 분포(geometric distribution)

```
In [50]: 1 x = np.random.geometric(p=1/3, size=10000)
```

```
In [53]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



분포

(이산형)

균열분포 : 사전확률

배치수 : 0과 1

이항분포 : 배치가 여러번

포아송 : 이벤트가 특정 시간발생할때 사용.

기하분포 : 1성공까지 시도횟수

(연속형)

균열분포

정규분포

감마분포 α 번째 사건까지 대기시간. $\alpha=1$ 면 지수분포

지수분포 $\alpha=1$ 인 감마분포

카이제곱분포 $\alpha = \frac{p}{2}$. $p=2$ 인 감마

베타분포 사후확률 in 베이저안

'이항분포의 정규근사' 관심있는사람 찾아보기

'포아송분포의 정규근사' 찾아보기

이항. 포아송. 감마. 베타 $\rightarrow$ 정규분포와 연결.

음이항분포 : 이번째 사건 발생 시점까지 시도 횟수 (기하분포와 관련)

분포들간의 관계 $\rightarrow$ 블로그참고

AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-1. 균일 분포

<양형 시작>

확률변수 X 가 셀 수 있는 것

이산형도 있음


균일 분포(uniform distribution)

: 확률 변수가 특정 값을 가질 확률이 모두 동일한 분포

Ex) 엘리베이터를 기다리고 있을 때 0초에서 30초 사이에 도착할 확률

시간-셀 수 없음

균일 분포(uniform distribution)



$$X \sim U(a, b)$$

확률밀도함수(PdF)

$$f_X(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

$$E(X) = \frac{b+a}{2}$$

$$Var(X) = \frac{(b-a)^2}{12}$$

균일 분포(uniform distribution)

In [16]: 1 x = np.random.uniform(low=1, high=6, size=100)

$1 \leq x < 6$ (범위)

6은 포함이 안됨.

5.999...까지 가능


→ 이것도 size만큼
구하면 균일하게
시각화됨

In [18]: 1 x


Out[18]: array([4.30117465, 1.38848184, 4.55317352, 2.40307571, 2.12733332,
3.35810487, 2.21065385, 3.70903142, 4.44881203, 3.86060373,
1.05664517, 4.5310821, 1.3659376, 3.3715056, 2.85010006,
5.70012, 4.07984033, 1.3853028, 1.82877964, 5.32519212,
1.13237288, 5.8131836, 5.42372129, 3.1328029, 2.43827832,
1.80824401, 5.06833961, 2.77806338, 2.27546544, 4.4757475,
1.6403327, 5.68993119, 5.13008485, 3.79717248, 4.9144149,
2.9664101, 2.23980611, 3.23513709, 3.25652101, 4.00430521,
2.24679711, 5.68831921, 1.48138707, 1.03214286, 1.73165645,
4.57576586, 4.26491185, 2.16419789, 5.90254064, 2.5897648,
3.00447209, 1.24025118, 4.51663526, 1.85566542, 3.40966549,
5.07187839, 3.69191643, 3.02022583, 5.89896572, 3.75946774,
4.04287198, 5.27050321, 3.20991749, 3.1051872, 1.44297797,
3.04659202, 3.90947227, 3.82804255, 2.97412838, 5.62558785,
2.58319113, 1.88947388, 1.94882864, 1.01845503, 1.10888513,
4.6793581, 2.60661655, 5.5448265, 2.042595, 2.80778224,
5.21249422, 1.4216494, 1.20759217, 2.57668654, 3.34367486,
4.40077969, 1.16417884, 5.21695766, 2.58287782, 3.76752704,
4.98538199, 1.84315719, 2.75170993, 1.86633562, 1.31778254,
3.51913987, 1.14481572, 5.99800488, 5.59340009, 1.60655536])

균일 분포(uniform distribution)

```
In [19]: 1 plt.hist(x, bins=30)  
         2 plt.show()
```



size를 커질수록
균일하게 수렴함



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-2. 정규 분포

정규 분포(normal distribution)

가우시안 distribution

: 가우스분포(gauss distribution)이라고도 부름


: 종 모양 분포

* 가장 유명한 분포

Q. 점추론을 ML에서 어떻게 쓸까?

(ex) 가우시안 naive bayes.

정규 분포(normal distribution)



* 정규분포의
P.d.f

$$X \sim N(\mu, \sigma^2)$$


$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad -\infty < x < \infty$$

평균값추천!
(시험은 x)


$$E(X) = \mu$$

$$Var(X) = \sigma^2$$

정규 분포(normal distribution)



정규 분포(normal distribution)



Q. 확률을 어떻게 구할지?

A. 적분. $\int_{80}^{\infty} f_X(x) dx$

극한값을 써야해서
어려움

표준분포

$$X \sim N(0, 1)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}, \quad -\infty < x < \infty$$

$$E(X) = 0$$

$$\text{Var}(X) = 1$$

↓
표준분포에 대해서
다 구해놓고 가져다 쓴다. (표준화)

정규 분포(normal distribution)

평균은 위치모수 (location parameter)


In [54]: 1 x = np.random.normal(loc=60, scale=6, size=100)

In [55]: 1 x

Out [55]: array([68.07508028, 52.14415089, 65.70165651, 61.62126503, 63.34439547,
55.45991631, 61.30793691, 61.92939211, 59.95537877, 49.63152242,
66.74807822, 62.20151669, 60.95961199, 58.27012522, 62.36398714,
58.28744404, 71.8162091 , 56.16490397, 66.2980992 , 51.8406372 ,
64.58079706, 55.34802362, 64.30817188, 62.30902607, 62.66777295,
57.19746904, 53.74464915, 55.37643073, 55.59036988, 74.50311647,
70.91931859, 54.32227686, 47.31439036, 56.92157356, 57.92362299,
53.49829763, 54.21987671, 71.09798723, 64.63178879, 56.78362873,
62.53315589, 63.73439005, 56.64253453, 73.50231542, 61.9776021 ,
55.6650955 , 54.73912306, 66.28228758, 69.75475368, 70.76468464,
61.83813356, 56.46127741, 64.11514854, 71.06465957, 61.94999696,
57.21323668, 61.14221242, 62.33604026, 68.58554615, 68.78179456,
51.64744656, 54.20539748, 59.91337173, 60.08762623, 61.05511687,
70.52218165, 60.41782439, 70.18336933, 63.37143359, 66.11314279,
56.52884755, 65.14810375, 67.31746738, 57.04345735, 66.4441253 ,
48.00136931, 66.90978186, 53.43305302, 58.10918506, 53.77367434,
55.51659164, 62.40429937, 67.16675802, 59.82067766, 61.15312333,
59.82600957, 61.70695571, 55.31309772, 57.42164718, 56.69585947,
65.77477629, 62.2112584 , 45.50270416, 46.75456409, 61.75627985,
67.23899264, 61.69208755, 52.41748979, 58.84465359, 56.10259938])

정규 분포(normal distribution)


```
In [56]: 1 plt.hist(x, bins=30)
        2 plt.show()
```



```
In [57]: 1 x = np.random.normal(loc=60, scale=6, size=1000)
```

size 1000

```
In [58]: 1 plt.hist(x, bins=30)
        2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-3. 감마분포

기하분포에서 이런 표현이 있었음.

감마 분포(gamma distribution)

: 알파 번째 사건이 발생할 때까지의 대기 시간의 분포

: 확률 변수가 가질 수 있는 값은 0부터 무한대까지

α 값

Ex) 어떤 게임에서 3번째 결제가 발생할때까지의 대기 시간

Ex) 인터넷 쇼핑몰에서 2번째 구매가 발생할 때까지의 대기 시간

α 값

감마 분포(gamma distribution)

감마 파는 성질: $\Gamma(\alpha) = (\alpha-1)!$
↖ 곱셈을 실수상으로 확장시킨 것

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{1}{\beta}x}, \quad 0 < x < \infty,$$

↖
정확

$$\alpha > 0,$$

↖
모양을 결정함




$$\beta > 0$$

↖ Scale parameter

$$E(X) = \alpha\beta$$

$$Var(X) = \alpha\beta^2$$

감마 분포(gamma distribution) 특징) 분포 모양이 변화무쌍함




저도 이렇게 앞으로 이해 것이다
· 실제 감마분포: 지금은 이런데 앞으로 분포가
변할 수 있다.

☆데이터가 많아야 유의미한 분포가 생성됨.

감마 분포(gamma distribution)


```
In [61]: 1 x = np.random.gamma(shape=2, scale=3, size=30)
```

```
In [62]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



```
In [63]: 1 x = np.random.gamma(shape=2, scale=3, size=1000)
```

```
In [64]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-4. 지수 분포

→ '지수분포의 무기억성' 과 관련.
(다음 사건이 왜 첫번째 사건과 같은지?)

신뢰성공학

지수 분포(exponential distribution) "α=1인 감마분포"

= 첫번째 사건이

: 다음 사건이 발생할 때까지의 대기 시간의 분포

: 확률 변수가 가질 수 있는 값은 0부터 무한대까지

감마분포에서 α=1인 경우

Q. 왜 따로 지수분포라고 하는지?

A. 중요하기 때문

* 지수분포 - 제조업·금융·보험업.

중요한 대기시간 → 보험료

Ex) 어떤 게임에서 다음 결제가 발생할때까지의 대기 시간

↓
제품의 고장 (제품수명)
까지의 시간

Ex) 인터넷 쇼핑몰에서 다음 구매가 발생할 때까지의 대기 시간

: 처음에 고장발 확률이 큼

지수 분포(exponential distribution)


$$f_X(x) = \frac{1}{\beta} e^{-\frac{1}{\beta}x}, \quad x > 0$$

$$E(X) = \beta$$

$$\text{Var}(X) = \beta^2$$

는 예일


지수 분포(exponential distribution)



지수 분포(exponential distribution)

```
In [65]: 1 x = np.random.exponential(scale=2, size=1000)
```

```
In [66]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-5. 카이제곱 분포

카이제곱 분포(chi-square distribution)

= 감마분포의 특이한 형태

= 감마분포에서 $\alpha = \frac{p}{2}$, $\beta = 2$ 인 경우

Q. 어디에 쓰는지?

→ 카이제곱검정에 씀.

→ 이 분포를 결정하는건 p 값

$X \sim \chi^2(p)$

p 는 자유도

$$X \sim \chi^2(p)$$

자유도가 p 인 카이제곱분포




$$f_X(x) = \frac{1}{\Gamma\left(\frac{p}{2}\right) 2^{\frac{p}{2}}} x^{\frac{p}{2}-1} e^{-\frac{1}{2}x}, \quad 0 < x < \infty$$

$$E(X) = p$$

$$\text{Var}(X) = 2p$$

카이제곱 분포(chi-square distribution)

그림 감마분포와 유사




카이제곱 분포(chi-square distribution)

In [67]: 1 `x = np.random.chisquare(df=3, size=1000)`

자유도 p

In [68]: 1 `plt.hist(x, bins=30)`
2 `plt.show()`



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-6. 베타분포

베타 분포(beta distribution) $\Rightarrow$ 베이지안에서 "사후확률"을 가정할때 쓰임. $P(\gamma|x)$

: 알파와 베타라는 매개 변수에 의해 정의 되는 확률 분포

: 0과 1사이에서 정의됨 γ 값이 0과 1사이에 있음.

: 모양이 다채롭다

* 베이지안에서 $P(\gamma)$ 는 균일분포 가정했었음.
균일분포 γ 값이 0과 1사이일수 있음

베타 분포(beta distribution)

$$f_X(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1, \quad \alpha > 0, \quad \beta > 0$$




$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$$


$$E(X) = \frac{\alpha}{\alpha + \beta}$$

$$Var(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

베타 분포(beta distribution)




베타 분포(beta distribution)




베타 분포(beta distribution)

In [71]: `1 x = np.random.beta(a=2,b=3, size=1000)`

In [72]: `1 plt.hist(x, bins=30)
2 plt.show()`



이런 데이터분포에서
데이터생성방법은?
→ 몬테카를로 방법



AI/BigData 인텐시브 과정

Section 4 추정 - 추측해서 정한다

Section 4-1. MLE

↳ 다음주 필요

MLE(Maximum Likelihood Estimator)

Likelihood를 **최대화** 하는 방법으로 추정!

Likelihood = 가능도, 우도

! 그럴듯한!

MLE(Maximum Likelihood Estimator)


확률
probability

vs


가능도
likelihood

비슷한데 바라보는 관점(다름).

MLE(Maximum Likelihood Estimator)




MLE(Maximum Likelihood Estimator)




MLE(Maximum Likelihood Estimator)


<likelihood> 이미 데이터가 있음. 무엇을 보려나? 분포를 보려.



MLE(Maximum Likelihood Estimator)




MLE(Maximum Likelihood Estimator)



MLE(Maximum Likelihood Estimator)

여러 개의 파라미터 후보 중에 어느 것이 **가장 그럴 듯** 할까?


MLE(Maximum Likelihood Estimator)



$$L(\theta|x) = \prod_{i=1}^n f(x_i|\theta)$$

$$\hat{\theta} = \operatorname{argmax}_{\theta} L(\theta|x) = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(x_i|\theta)$$

MLE(Maximum Likelihood Estimator)






$$l(\theta|x) = \log L(\theta|x) = \log \left(\prod_{i=1}^n f(x_i|\theta) \right) = \sum_{i=1}^n \log f(x_i|\theta)$$



로그를 취하는 이유


- 가능도 함수에 로그를 취해도 로그함수는 1대1 함수이므로 성질은 변하지 않음
- 빅데이터에 적용하면 가능도는 0에 수렴하므로 계산상의 오류가 발생할 가능성

MLE(Maximum Likelihood Estimator)









MLE(Maximum Likelihood Estimator)

서로 독립인 표본 x_1, x_2 를 평균 $\mu = \theta$, 분산 $\sigma^2 = 1$ 인 정규분포에서 얻은 표본

$$f_X(x_1|\theta) = \frac{1}{\sqrt{2\pi} \times 1} e^{-\frac{1}{2}\left(\frac{x_1-\theta}{1}\right)^2}$$

$$L = f_X(x_1|\theta) \times f_X(x_2|\theta)$$

$$f_X(x_2|\theta) = \frac{1}{\sqrt{2\pi} \times 1} e^{-\frac{1}{2}\left(\frac{x_2-\theta}{1}\right)^2}$$

$$= \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_1-\theta}{1}\right)^2} \times \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_2-\theta}{1}\right)^2}$$

MLE(Maximum Likelihood Estimator)

서로 독립인 표본 x_1, x_2 를 평균 $\mu = \theta$, 분산 $\sigma^2 = 1$ 인 정규분포에서 얻은 표본

$$\frac{\partial \log L}{\partial \theta} \equiv 0$$

$$\hat{\theta} = \frac{x_1 + x_2}{2}$$

$$\frac{\partial \log L}{\partial \theta} = (x_1 - \theta) + (x_2 - \theta) \equiv 0$$

$$\leftrightarrow \hat{\theta} = \frac{x_1 + x_2}{2}$$

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i$$

MLE(Maximum Likelihood Estimator)

서로 독립인 표본 x_1, x_2 를 평균 $\mu = \theta$, 분산 $\sigma^2 = 1$ 인 정규분포에서 얻은 표본

$$\frac{\partial^2 \log L}{\partial^2 \theta} < 0$$

$$\frac{\partial \log L}{\partial \theta} = (x_1 - \theta) + (x_2 - \theta)$$

$$= x_1 + x_2 - 2\theta$$

$$\frac{\partial^2 \log L}{\partial^2 \theta} = -2 < 0$$

AI/BigData 인텐시브 과정

Section 4. 추정

Section 4-2. MAP

MAP(Maximum A Posterior)

빈도주의(Frequentist)

VS

베이지안(Bayesian)

파라미터는 상수!

파라미터는 확률 변수!

MAP(Maximum A Posterior)

θ 하에서 데이터의 분포

Likelihood

데이터를 관측하기 전 θ 의 분포

사전 확률 밀도 함수

(prior probability density function)

$$\boxed{f(\theta|x)} = \frac{f(\theta, x)}{f(x)} = \frac{f(x|\theta)f(\theta)}{f(x)} = \frac{f(x|\theta)f(\theta)}{\int f(x|\theta)f(\theta)d\theta}$$

사후 확률 밀도 함수

(posterior probability density function)

데이터를 관측한 후 θ 의 분포

MAP(Maximum A Posterior)

$$\hat{\theta}_{MAP} = \operatorname{argmax}_{\theta} f(\theta|x)$$

$$= \operatorname{argmax}_{\theta} \frac{f(x|\theta)f(\theta)}{\int f(x|\theta)f(\theta)}$$

$$\propto \operatorname{argmax}_{\theta} f(x|\theta)f(\theta)$$

MLE vs MAP

$$\hat{\theta}_{MLE} = \operatorname{argmax}_{\theta} f(x|\theta)$$

사전 확률을 고려하지 않음

$$\hat{\theta}_{MAP} = \operatorname{argmax}_{\theta} f(x|\theta)f(\theta)$$

사전 확률을 고려함

MAP(Maximum A Posterior)

파라미터 θ 의 사전 분포 $f(\theta)$

$$f(\theta) = 2\theta, \quad 0 \leq \theta \leq 1$$

파라미터 θ 가 주어졌을 때의 표본 x 의 분포

$$x|\theta \sim \text{Geometric}(\theta)$$

$$f(x|\theta) = \theta(1 - \theta)^{x-1}, \quad x = 1, 2, 3, \dots$$

x 가 $x = 3$ 으로 주어졌을 때의 파라미터 θ 의 MAP는 ??

MAP(Maximum A Posterior)

파라미터 θ 가 주어졌을 때 $x = 3$ 일 확률 밀도

$$f(3|\theta) = \theta(1 - \theta)^2$$

파라미터 θ 의 사후 분포

$$f(\theta|x) = f(x|\theta)f(\theta)$$

$$= \theta(1 - \theta)^2 \cdot 2\theta$$

$$= 2\theta^2(1 - \theta)^2$$

MAP(Maximum A Posterior)

사후 분포를 최대로 하는 파라미터 θ 를 찾기 위해 θ 에 대해 미분해서 0되는 값 찾기

$$\frac{d}{d\theta} f(\theta|x) = \frac{d}{d\theta} [2\theta^2(1-\theta)^2]$$

$$= 4\theta(1-\theta)^2 + 2\theta^2 \cdot 2(1-\theta)(-1)$$

$$= 4\theta(1-\theta)^2 - 4\theta^2(1-\theta)$$

$$4\theta(1-\theta)^2 - 4\theta^2(1-\theta) \equiv 0$$

$$\Leftrightarrow 4\theta(1-\theta)^2 = 4\theta^2(1-\theta)$$

$$\Leftrightarrow 1-\theta = \theta$$

$$\Leftrightarrow \hat{\theta}_{MAP} = \frac{1}{2}$$

감사합니다.

Q & A