

AI/BigData 인텐시브 과정

강사장철원

Section 0

코스소개

DAY1

DAY2

DAY3

DAY4

DAY5

데이터 분석을 위한 기초 수학

데이터 집계 및 시각화

DAY6

DAY7

DAY8

DAY9

DAY10

미니
프로젝트

확률분포, AB테스트

DAY11

DAY12

DAY13

DAY14

DAY15

머신러닝

DAY16

DAY17

DAY18

DAY19

DAY20

딥러닝

파이널 프로젝트

□ 확률분포

□ 이산형 확률분포

□ 연속형 확률분포

AI/BigData 인텐시브 과정


Section 1. 확률 분포

Section 1-1. 확률 분포의 개념

히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간


50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램

유저별 게임 플레이 시간

50, 60, 65, 71, 73, 78, 81, 84, 89, 94




구간이 달라지면?

히스토그램

유저별 게임 플레이 시간

50, 60, 65, 71, 73, 78, 81, 84, 89, 94



히스토그램


In [9]:

```
1 df.describe()
```


Out[9]:

		ACHIEVEMENT	ABILITY	ATTITUDE
데이터 행(row) 수	←	count	1000.000000	1000.000000
평균	←	mean	66.08900	69.169000
표준편차	←	std	15.16308	14.600192
최소값	←	min	0.00000	17.000000
Q1	←	25%	57.00000	59.000000
중앙값, Q2	←	50%	66.00000	70.000000
Q3	←	75%	77.00000	79.000000
최대값	←	max	100.00000	100.000000


히스토그램



히스토그램



히스토그램




히스토그램

In [6]:

```
1 import seaborn as sns
2
3 sns.histplot(data=df, x="ACHIEVEMENT")
```


Out[6]: <AxesSubplot:xlabel='ACHIEVEMENT', ylabel='Count'>



확률 분포(probability distribution)


확률 분포(probability distribution): 확률 변수가 특정한 값을 가질 확률을 나타내는 함수

확률 분포(probability distribution)의 종류



확률 질량 함수(probability mass function, pmf)

이산 확률 변수에서 특정 값에 대한 확률을 나타내는 함수



$$P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$


연속 확률 변수에서 특정 구간에 포함될 확률을 나타내는 함수

확률 밀도 함수(probability density function, pdf)

5분에 한대씩 오는 버스가 있을 때,
철수가 정류장에서 버스가 올때 까지 기다리는 시간 x

$$f_X(x) = \frac{1}{5}, \quad 0 \leq x \leq 5$$



철수가 버스 도착까지 0분에서 2분사이로 기다릴 확률



$$P(0 \leq X \leq 2) = \int_0^2 \frac{1}{5} dx$$

확률 밀도 함수(probability density function, pdf)


$$P(a \leq X \leq b) = \int_a^b f_X(x) dx$$



누적분포함수(cumulative distribution function) - 이산형

주어진 확률 변수가 특정 값보다 작거나 같은 확률


$$F_X(x) = P(X \leq x) = \sum_{X \leq x} P(X = x)$$



누적분포함수(cumulative distribution function) - 연속형

주어진 확률 변수가 특정 값보다 작거나 같은 확률

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(u) du$$



기대값(Expected Value)

확률 변수의 평균적인 값

기대값은 확률 질량 함수나 확률 밀도 함수로 정의됨

이산 확률 변수의 기대값

$$E(X) = \sum_x x \cdot P(X = x)$$

연속 확률 변수의 기대값

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

분산(Variance)

이산 확률 변수의 분산

$$Var(X) = E[(X - \mu)^2] = \sum_x (x - \mu)^2 P(X = x)$$

연속 확률 변수의 분산

$$Var(X) = E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x) dx$$

분산(Variance)

$$Var(X) = E[(X - \mu)^2] = E[X^2 - 2X\mu + \mu^2]$$

$$= E(X^2) - 2\mu E(X) + \mu^2$$

$$= E(X^2) - 2\mu^2 + \mu^2$$

$$= E(X^2) - \mu^2$$

기대값(Expected Value) - 이산형 예제

주사위를 한 번 던질 때 나오는 수를 확률 변수 X 라고 했을 때 X 의 기대값 구하기

$$P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$

$$E(X) = \sum_{x=1}^6 x \cdot P(X = x) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = 3.5$$

분산(Variance) - 이산형 예제

주사위를 한 번 던질 때 나오는 수를 확률 변수 X 라고 했을 때 X 의 분산

$$P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$

$$Var(X) = E[(X - \mu)^2] = \sum_{x=1}^6 (x - \mu)^2 P(X = x) = \sum_{x=1}^6 (x - 3.5)^2 \cdot \frac{1}{6} = 2.91$$

기대값(Expected Value) - 연속형 예제

확률 변수 X 의 기대값 구하기

$$f_X(x) = \frac{1}{10}, \quad 0 \leq x \leq 10$$

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx = \int_0^{10} x \cdot \frac{1}{10} dx = \frac{1}{10} \int_0^{10} x dx = \frac{1}{10} \left[\frac{x^2}{2} \right]_0^{10} = \frac{1}{10} \cdot \frac{100}{2} = 5$$

분산(Variance) - 연속형 예제

확률 변수 X 의 분산

$$f_X(x) = \frac{1}{10}, \quad 0 \leq x \leq 10$$

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x) dx = \frac{1}{10} \int_0^{10} (x - 5)^2 dx = \frac{1}{10} \cdot \frac{1}{3} [(x - 5)^3]_0^{10}$$

$$= \frac{1}{10} \cdot \frac{1}{3} [(10 - 5)^3 - (0 - 5)^3] = \frac{1}{30} (125 + 125) = \frac{250}{30} = 8.33$$

AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-1. 균일 분포

균일 분포(uniform distribution)


균일 분포(uniform distribution)

: 확률 변수가 특정 값을 가질 확률이 모두 동일한 분포

Ex) 동전을 던졌을 때, 앞면, 뒷면이 각각 나올 확률

Ex) 주사위를 던졌을 때, 1, 2, 3, 4, 5, 6이 각각 나올 확률

균일 분포(uniform distribution)



$$X \sim U(1, 6)$$

$$P(X = x) = \frac{1}{6}, \quad x = 1, 2, 3, 4, 5, 6$$

$$P(X = 1) = \frac{1}{6}$$

$$P(X = 4) = \frac{1}{6}$$


$$P(X = 2) = \frac{1}{6}$$

$$P(X = 5) = \frac{1}{6}$$

$$P(X = 3) = \frac{1}{6}$$

$$P(X = 6) = \frac{1}{6}$$

균일 분포(uniform distribution)




$$X \sim U(1, N)$$

$$P(X = x) = \frac{1}{N}, \quad x = 1, 2, \dots, N$$

$$E(X) = \frac{N + 1}{2}$$

$$Var(X) = \frac{(N + 1)(N - 1)}{12}$$

균일 분포(uniform distribution)




$$X \sim U(1, 5)$$

$$P(X = x) = \frac{1}{5}, \quad x = 1, 2, \dots, 5$$

$$E(X) = \frac{5 + 1}{2}$$

$$\text{Var}(X) = \frac{(5 + 1)(5 - 1)}{12}$$

균일 분포(uniform distribution)



$$X \sim U(a, b)$$

$$P(X = x) = \frac{1}{b - a + 1}, \quad x = a, a + 1, \dots, b$$

$$E(X) = \frac{a + b}{2}$$

$$\text{Var}(X) = \frac{(b - a + 1)^2 - 1}{12}$$

균일 분포(uniform distribution)


```
In [5]: 1 import numpy as np
        2 import pandas as pd
        3 import matplotlib.pyplot as plt
```

```
In [20]: 1 x = np.random.randint(low=1, high=6, size=100)
```

```
In [21]: 1 x
```

```
Out[21]: array([2, 2, 4, 5, 5, 2, 1, 4, 1, 3, 4, 4, 5, 2, 1, 2, 1, 5, 2, 3, 5, 1,
                1, 4, 1, 5, 2, 3, 5, 4, 1, 4, 2, 2, 2, 4, 5, 5, 5, 4, 3, 2, 3, 1,
                2, 2, 4, 4, 1, 5, 3, 4, 5, 2, 5, 4, 1, 4, 4, 4, 3, 5, 5, 1, 3, 1,
                4, 3, 2, 1, 5, 4, 4, 5, 3, 4, 5, 5, 5, 4, 3, 5, 1, 1, 1, 4, 1, 1,
                5, 4, 5, 1, 4, 4, 5, 5, 5, 2, 5, 3])
```


```
In [26]: 1 plt.hist(x, bins=10)
        2 plt.show()
```



균일 분포(uniform distribution)

```
In [27]: 1 x = np.random.randint(low=1, high=6, size=10000)
```

```
In [28]: 1 plt.hist(x, bins=10)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-2. 베르누이 분포

베르누이 분포(Bernoulli distribution)

: 확률 변수가 가질 수 있는 값이 0 혹은 1

: 이 때 0 혹은 1이라는 말은 실패면 0, 성공이면 1이라고 할 수 있음

: 성공 확률이 p 이면 실패 확률은 $1-p$


: 한 번 시행했을 때의 성공 횟수

: 시행을 한 번만 하므로 베르누이 시행이라고도 함

Ex) 동전을 던졌을 때 앞면이 나오는 경우가 성공이라고 할 경우, 성공할 확률은?

Ex) 주사위를 던졌을 때 6이 나오는 경우가 성공이라고 할 경우, 성공할 확률은?

베르누이 분포(Bernoulli distribution)




$$P(X = x) = p^x(1 - p)^{1-x}, \quad x = 0, 1$$

$$E(X) = p$$

$$\text{Var}(X) = p(1 - p)$$

베르누이 분포(Bernoulli distribution)



$$p = 0.6$$

$$P(X = x) = 0.6^x (1 - 0.6)^{1-x}, \quad x = 0, 1$$

$$E(X) = 0.6$$

$$\text{Var}(X) = 0.6(1 - 0.6) = 0.24$$


베르누이 분포(Bernoulli distribution)

```
In [29]: 1 x = np.random.binomial(n=1, p=1/3, size=100)
```

```
In [30]: 1 x
```

```
Out[30]: array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 0, 1, 0, 1, 0, 1, 1, 1,
                0, 1, 1, 0, 0, 1, 1, 0, 1, 0, 0, 0, 1, 1, 0, 0, 0, 1, 0, 0, 0, 0,
                0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0,
                0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 0, 1, 0, 0, 1, 0, 0, 0, 0,
                0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0])
```


```
In [32]: 1 plt.hist(x, bins=3)
        2 plt.show()
```



베르누이 분포(Bernoulli distribution)

```
In [33]: 1 x = np.random.binomial(n=1, p=1/3, size=1000)
```

```
In [34]: 1 plt.hist(x, bins=3)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-3. 이항 분포

이항 분포(binomial distribution)

: 이항 분포는 독립적으로 베르누이 시행을 n 번 한 경우의 총 성공 횟수

: 확률 변수가 가질 수 있는 값은 0부터 n 까지

: 0은 모든 시행이 실패한 경우, n 은 모든 시행이 성공한 경우

: 각 시행의 성공 확률이 p 이면 실패 확률은 $1-p$


이항 분포(binomial distribution)

이항 분포(binomial distribution)의 예

Ex) 동전을 던졌을 때 앞면이 나오는 경우가 성공이라고 할 경우,
다섯 번 던졌을 때의 성공 횟수는?

Ex) 주사위를 던졌을 때 6이 나오는 경우가 성공이라고 할 경우,
10번 던졌을 때의 성공 횟수는?

이항 분포(binomial distribution)



$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, \quad x = 0, 1, \dots, n$$

$$\binom{n}{x} = \frac{n!}{x! (n - x)!}$$

$$E(X) = np$$

$$Var(X) = np(1 - p)$$


이항 분포(binomial distribution)

```
In [2]: 1 x = np.random.binomial(n=10, p=1/3, size=100)
```

```
In [3]: 1 x
```

```
Out[3]: array([3, 3, 5, 6, 4, 4, 4, 2, 4, 4, 3, 5, 3, 1, 3, 4, 2, 2, 3, 5, 5, 3,
               4, 5, 2, 4, 4, 3, 3, 2, 3, 4, 5, 1, 2, 4, 1, 4, 3, 2, 5, 2, 4, 1,
               6, 3, 4, 4, 3, 3, 2, 4, 4, 3, 1, 5, 1, 2, 4, 3, 4, 3, 1, 4, 2, 2,
               3, 4, 5, 5, 2, 3, 7, 4, 3, 4, 2, 5, 4, 3, 6, 1, 2, 6, 3, 2, 1, 3,
               3, 4, 3, 2, 2, 2, 4, 4, 3, 4, 1, 5])
```


```
In [8]: 1 plt.hist(x, bins=30)
        2 plt.show()
```



이항 분포(binomial distribution)

```
In [9]: 1 x2 = np.random.binomial(n=10, p=1/3, size=1000)
```

```
In [12]: 1 plt.hist(x2, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-4. 포아송 분포

포아송 분포(poisson distribution)

: 단위 시간 동안 관심있는 이벤트가 몇 번 발생할 것인지를 나타내는 분포

: 확률 변수가 가질 수 있는 값은 0부터 무한대까지

Ex) 어떤 게임에서 1분 동안 결제하는 유저 수가 3명 이상일 확률은?

Ex) 인터넷 쇼핑몰에서 1시간 동안 구매 취소하는 구매자 수가 5명 이상일 확률?

포아송 분포(poisson distribution)

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, \dots$$


$$e^{\lambda} = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$$

$$E(X) = \lambda$$


$$Var(X) = \lambda$$

포아송 분포(poisson distribution)

$$\lambda = 5$$



$$\lambda = 15$$




포아송 분포(poisson distribution)

```
In [36]: 1 x = np.random.poisson(lam=2, size=100)
```

```
In [37]: 1 x
```

```
Out[37]: array([0, 1, 2, 2, 0, 1, 5, 2, 3, 3, 3, 2, 1, 2, 5, 3, 3, 2, 3, 0, 3, 1,  
                2, 1, 2, 4, 0, 1, 4, 3, 2, 4, 1, 1, 2, 3, 3, 1, 2, 1, 2, 0, 1, 1,  
                3, 3, 2, 2, 2, 1, 2, 1, 3, 4, 3, 2, 3, 1, 1, 1, 2, 1, 1, 3, 0, 1,  
                1, 2, 0, 0, 2, 1, 2, 1, 2, 2, 2, 2, 1, 2, 1, 1, 7, 1, 1, 3, 4, 1,  
                2, 1, 3, 4, 5, 0, 0, 3, 3, 2, 0, 5])
```

```
In [38]: 1 plt.hist(x, bins=30)  
        2 plt.show()
```




포아송 분포(poisson distribution)

```
In [42]: 1 x = np.random.poisson(lam=2, size=10000)
```

```
In [43]: 1 x
```

```
Out[43]: array([2, 1, 2, ..., 1, 5, 0])
```

```
In [44]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 1. 이산형 확률 분포

Section 1-5. 기하분포

기하 분포(geometric distribution)


: 처음 성공할 때까지 시도한 횟수(X)의 분포

: 처음 성공할 때까지의 실패 횟수(Y)의 분포

$$Y = X - 1$$

$$X = 7$$

처음 성공 할 때까지의 시도 횟수



$$Y = 6$$

처음 성공 할 때까지의 실패 횟수 $(Y = X - 1)$

기하 분포(geometric distribution)



X = 처음 성공할때까지의 시도 횟수

$$P(X = x) = p(1 - p)^{x-1}, \quad x = 1, 2, \dots$$

$$E(X) = \frac{1}{p}$$

$$Var(X) = \frac{1 - p}{p^2}$$

기하 분포(geometric distribution)




기하 분포(geometric distribution)

```
In [47]: 1 x = np.random.geometric(p=1/3, size=100)
```

```
In [48]: 1 x
```

```
Out[48]: array([ 1,  1,  4,  1,  3,  1,  2,  8,  6,  4,  2,  6,  4,  8,  2,  1,  3,  
                5,  1,  1, 11,  2,  2,  1,  2,  1,  1,  2,  4,  1,  2,  6,  4,  1,  
                1,  1,  1,  1,  1,  6,  4,  2,  4,  3,  1,  4,  1,  2,  1,  3,  1,  
                5,  5,  5,  7,  2,  6,  5,  1,  2,  2,  2,  1,  6,  1,  1,  1,  3,  
                3,  5,  3,  2,  1,  3,  1,  2,  1,  1,  1,  3,  2,  1,  2,  1,  1,  
                3,  2,  1,  1,  1,  3,  2,  2,  1,  2,  4,  1,  5,  5,  3])
```


```
In [49]: 1 plt.hist(x, bins=30)  
        2 plt.show()
```



기하 분포(geometric distribution)

```
In [50]: 1 x = np.random.geometric(p=1/3, size=10000)
```

```
In [53]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포


Section 2-1. 균일 분포

균일 분포(uniform distribution)

: 확률 변수가 특정 값을 가질 확률이 모두 동일한 분포

Ex) 엘리베이터를 기다리고 있을 때 0초에서 30초 사이에 도착할 확률

균일 분포(uniform distribution)



$$X \sim U(a, b)$$

$$f_X(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

$$E(X) = \frac{b+a}{2}$$

$$Var(X) = \frac{(b-a)^2}{12}$$

균일 분포(uniform distribution)


```
In [16]: 1 x = np.random.uniform(low=1, high=6, size=100)
```

```
In [18]: 1 x
```

```
Out[18]: array([4.30117465, 1.38848184, 4.55317352, 2.40307571, 2.12733332,  
                3.35810487, 2.21065385, 3.70903142, 4.44881203, 3.86060373,  
                1.05664517, 4.5310821 , 1.3659376 , 3.3715056 , 2.85010006,  
                5.70012   , 4.07984033, 1.3853028 , 1.82877964, 5.32519212,  
                1.13237288, 5.8131836 , 5.42372129, 3.1328029 , 2.43827832,  
                1.80824401, 5.06833961, 2.77806338, 2.27546544, 4.4757475 ,  
                1.6403327 , 5.68993119, 5.13008485, 3.79717248, 4.9144149 ,  
                2.9664101 , 2.23980611, 3.23513709, 3.25652101, 4.00430521,  
                2.24679711, 5.68831921, 1.48138707, 1.03214286, 1.73165645,  
                4.57576586, 4.26491185, 2.16419789, 5.90254064, 2.5897648 ,  
                3.00447209, 1.24025118, 4.51663526, 1.85566542, 3.40966549,  
                5.07187839, 3.69191643, 3.02022583, 5.89896572, 3.75946774,  
                4.04287198, 5.27050321, 3.20991749, 3.1051872 , 1.44297797,  
                3.04659202, 3.90947227, 3.82804255, 2.97412838, 5.62558785,  
                2.58319113, 1.88947388, 1.94882864, 1.01845503, 1.10888513,  
                4.6793581 , 2.60661655, 5.5448265 , 2.042595 , 2.80778224,  
                5.21249422, 1.4216494 , 1.20759217, 2.57668654, 3.34367486,  
                4.40077969, 1.16417884, 5.21695766, 2.58287782, 3.76752704,  
                4.98538199, 1.84315719, 2.75170993, 1.86633562, 1.31778254,  
                3.51913987, 1.14481572, 5.99800488, 5.59340009, 1.60655536])
```

균일 분포(uniform distribution)

```
In [19]: 1 plt.hist(x, bins=30)  
         2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-2. 정규 분포


정규 분포(normal distribution)

: 가우스분포(gauss distribution)이라고도 부름

: 종 모양 분포

: 가장 유명한 분포

정규 분포(normal distribution)




$$X \sim N(\mu, \sigma^2)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad -\infty < x < \infty$$


$$E(X) = \mu$$

$$\text{Var}(X) = \sigma^2$$

정규 분포(normal distribution)



정규 분포(normal distribution)



$$X \sim N(0, 1)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}, \quad -\infty < x < \infty$$

$$E(X) = 0$$

$$Var(X) = 1$$

정규 분포(normal distribution)


```
In [54]: 1 x = np.random.normal(loc=60, scale=6, size=100)
```

```
In [55]: 1 x
```

```
Out [55]: array([68.07508028, 52.14415089, 65.70165651, 61.62126503, 63.34439547,  
55.45991631, 61.30793691, 61.92939211, 59.95537877, 49.63152242,  
66.74807822, 62.20151669, 60.95961199, 58.27012522, 62.36398714,  
58.28744404, 71.8162091 , 56.16490397, 66.2980992 , 51.8406372 ,  
64.58079706, 55.34802362, 64.30817188, 62.30902607, 62.66777295,  
57.19746904, 53.74464915, 55.37643073, 55.59036988, 74.50311647,  
70.91931859, 54.32227686, 47.31439036, 56.92157356, 57.92362299,  
53.49829763, 54.21987671, 71.09798723, 64.63178879, 56.78362873,  
62.53315589, 63.73439005, 56.64253453, 73.50231542, 61.9776021 ,  
55.6650955 , 54.73912306, 66.28228758, 69.75475368, 70.76468464,  
61.83813356, 56.46127741, 64.11514854, 71.06465957, 61.94999696,  
57.21323668, 61.14221242, 62.33604026, 68.58554615, 68.78179456,  
51.64744656, 54.20539748, 59.91337173, 60.08762623, 61.05511687,  
70.52218165, 60.41782439, 70.18336933, 63.37143359, 66.11314279,  
56.52884755, 65.14810375, 67.31746738, 57.04345735, 66.4441253 ,  
48.00136931, 66.90978186, 53.43305302, 58.10918506, 53.77367434,  
55.51659164, 62.40429937, 67.16675802, 59.82067766, 61.15312333,  
59.82600957, 61.70695571, 55.31309772, 57.42164718, 56.69585947,  
65.77477629, 62.2112584 , 45.50270416, 46.75456409, 61.75627985,  
67.23899264, 61.69208755, 52.41748979, 58.84465359, 56.10259938])
```


정규 분포(normal distribution)

```
In [56]: 1 plt.hist(x, bins=30)
          2 plt.show()
```



```
In [57]: 1 x = np.random.normal(loc=60, scale=6, size=1000)
```

```
In [58]: 1 plt.hist(x, bins=30)
          2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-3. 감마분포

감마 분포(gamma distribution)

: 알파 번째 사건이 발생할 때까지의 대기 시간의 분포

: 확률 변수가 가질 수 있는 값은 0부터 무한대까지

Ex) 어떤 게임에서 3번째 결제가 발생할때까지의 대기 시간

Ex) 인터넷 쇼핑몰에서 2번째 구매가 발생할 때까지의 대기 시간




감마 분포(gamma distribution)

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{1}{\beta}x}, \quad 0 < x < \infty, \quad \alpha > 0, \quad \beta > 0$$

$$E(X) = \alpha\beta$$

$$Var(X) = \alpha\beta^2$$


감마 분포(gamma distribution)



감마 분포(gamma distribution)


```
In [61]: 1 x = np.random.gamma(shape=2, scale=3, size=30)
```

```
In [62]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



```
In [63]: 1 x = np.random.gamma(shape=2, scale=3, size=1000)
```

```
In [64]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-4. 지수 분포

지수 분포(exponential distribution)

: 다음 사건이 발생할 때까지의 대기 시간의 분포

: 확률 변수가 가질 수 있는 값은 0부터 무한대까지

Ex) 어떤 게임에서 다음 결제가 발생할때까지의 대기 시간

Ex) 인터넷 쇼핑몰에서 다음 구매가 발생할 때까지의 대기 시간


지수 분포(exponential distribution)

$$f_X(x) = \frac{1}{\beta} e^{-\frac{1}{\beta}x}, \quad x > 0$$

$$E(X) = \beta$$

$$Var(X) = \beta^2$$


지수 분포(exponential distribution)



지수 분포(exponential distribution)

```
In [65]: 1 x = np.random.exponential(scale=2, size=1000)
```

```
In [66]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-5. 카이제곱 분포




카이제곱 분포(chi-square distribution)

$$f_X(x) = \frac{1}{\Gamma\left(\frac{p}{2}\right) 2^{\frac{p}{2}}} x^{\frac{p}{2}-1} e^{-\frac{1}{2}x}, \quad 0 < x < \infty$$

$$E(X) = p$$

$$Var(X) = 2p$$


카이제곱 분포(chi-square distribution)



카이제곱 분포(chi-square distribution)

```
In [67]: 1 x = np.random.chisquare(df=3, size=1000)
```

```
In [68]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 2. 연속형 확률 분포

Section 2-6. 베타분포

베타 분포(beta distribution)

: 알파와 베타라는 매개 변수에 의해 정의 되는 확률 분포

: 0과 1사이에서 정의됨

베타 분포(beta distribution)

$$f_X(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1, \quad \alpha > 0, \quad \beta > 0$$


$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$$


$$E(X) = \frac{\alpha}{\alpha + \beta}$$

$$Var(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

베타 분포(beta distribution)




베타 분포(beta distribution)



베타 분포(beta distribution)

```
In [71]: 1 x = np.random.beta(a=2,b=3, size=1000)
```

```
In [72]: 1 plt.hist(x, bins=30)  
2 plt.show()
```



AI/BigData 인텐시브 과정

Section 4. 추정

Section 4-1. MLE

MLE(Maximum Likelihood Estimator)

Likelihood를 **최대화** 하는 방법으로 추정!

Likelihood = 가능도, 우도


MLE(Maximum Likelihood Estimator)

확률
probability


vs

가능도
likelihood


MLE(Maximum Likelihood Estimator)




MLE(Maximum Likelihood Estimator)




MLE(Maximum Likelihood Estimator)



MLE(Maximum Likelihood Estimator)




MLE(Maximum Likelihood Estimator)



MLE(Maximum Likelihood Estimator)

여러 개의 파라미터 후보 중에 어느 것이 **가장 그럴 듯** 할까?


MLE(Maximum Likelihood Estimator)



$$L(\theta|x) = \prod_{i=1}^n f(x_i|\theta)$$

$$\hat{\theta} = \operatorname{argmax}_{\theta} L(\theta|x) = \operatorname{argmax}_{\theta} \prod_{i=1}^n f(x_i|\theta)$$

MLE(Maximum Likelihood Estimator)






$$l(\theta|x) = \log L(\theta|x) = \log \left(\prod_{i=1}^n f(x_i|\theta) \right) = \sum_{i=1}^n \log f(x_i|\theta)$$



로그를 취하는 이유


- 가능도 함수에 로그를 취해도 로그함수는 1대1 함수이므로 성질은 변하지 않음
- 빅데이터에 적용하면 가능도는 0에 수렴하므로 계산상의 오류가 발생할 가능성

MLE(Maximum Likelihood Estimator)









MLE(Maximum Likelihood Estimator)

서로 독립인 표본 x_1, x_2 를 평균 $\mu = \theta$, 분산 $\sigma^2 = 1$ 인 정규분포에서 얻은 표본

$$f_X(x_1|\theta) = \frac{1}{\sqrt{2\pi} \times 1} e^{-\frac{1}{2}\left(\frac{x_1-\theta}{1}\right)^2}$$

$$L = f_X(x_1|\theta) \times f_X(x_2|\theta)$$

$$f_X(x_2|\theta) = \frac{1}{\sqrt{2\pi} \times 1} e^{-\frac{1}{2}\left(\frac{x_2-\theta}{1}\right)^2}$$

$$= \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_1-\theta}{1}\right)^2} \times \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x_2-\theta}{1}\right)^2}$$

MLE(Maximum Likelihood Estimator)

서로 독립인 표본 x_1, x_2 를 평균 $\mu = \theta$, 분산 $\sigma^2 = 1$ 인 정규분포에서 얻은 표본

$$\frac{\partial \log L}{\partial \theta} \equiv 0$$

$$\hat{\theta} = \frac{x_1 + x_2}{2}$$

$$\frac{\partial \log L}{\partial \theta} = (x_1 - \theta) + (x_2 - \theta) \equiv 0$$

$$\leftrightarrow \hat{\theta} = \frac{x_1 + x_2}{2}$$

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i$$

MLE(Maximum Likelihood Estimator)

서로 독립인 표본 x_1, x_2 를 평균 $\mu = \theta$, 분산 $\sigma^2 = 1$ 인 정규분포에서 얻은 표본

$$\frac{\partial^2 \log L}{\partial^2 \theta} < 0$$

$$\frac{\partial \log L}{\partial \theta} = (x_1 - \theta) + (x_2 - \theta)$$

$$= x_1 + x_2 - 2\theta$$

$$\frac{\partial^2 \log L}{\partial^2 \theta} = -2 < 0$$

AI/BigData 인텐시브 과정

Section 4. 추정

Section 4-2. MAP

MAP(Maximum A Posterior)

빈도주의(Frequentist)

VS

베이지안(Bayesian)

파라미터는 상수!

파라미터는 확률 변수!

MAP(Maximum A Posterior)

θ 하에서 데이터의 분포

Likelihood

데이터를 관측하기 전 θ 의 분포

사전 확률 밀도 함수

(prior probability density function)

$$\boxed{f(\theta|x)} = \frac{f(\theta, x)}{f(x)} = \frac{f(x|\theta)f(\theta)}{f(x)} = \frac{f(x|\theta)f(\theta)}{\int f(x|\theta)f(\theta)d\theta}$$

사후 확률 밀도 함수

(posterior probability density function)

데이터를 관측한 후 θ 의 분포

MAP(Maximum A Posterior)

$$\hat{\theta}_{MAP} = \operatorname{argmax}_{\theta} f(\theta|x)$$

$$= \operatorname{argmax}_{\theta} \frac{f(x|\theta)f(\theta)}{\int f(x|\theta)f(\theta)}$$

$$\propto \operatorname{argmax}_{\theta} f(x|\theta)f(\theta)$$

MLE vs MAP

$$\hat{\theta}_{MLE} = \operatorname{argmax}_{\theta} f(x|\theta)$$

사전 확률을 고려하지 않음

$$\hat{\theta}_{MAP} = \operatorname{argmax}_{\theta} f(x|\theta)f(\theta)$$

사전 확률을 고려함

MAP(Maximum A Posterior)

파라미터 θ 의 사전 분포 $f(\theta)$

$$f(\theta) = 2\theta, \quad 0 \leq \theta \leq 1$$

파라미터 θ 가 주어졌을 때의 표본 x 의 분포

$$x|\theta \sim \text{Geometric}(\theta)$$

$$f(x|\theta) = \theta(1 - \theta)^{x-1}, \quad x = 1, 2, 3, \dots$$

x 가 $x = 3$ 으로 주어졌을 때의 파라미터 θ 의 MAP는 ??

MAP(Maximum A Posterior)

파라미터 θ 가 주어졌을 때 $x = 3$ 일 확률 밀도

$$f(3|\theta) = \theta(1 - \theta)^2$$

파라미터 θ 의 사후 분포

$$f(\theta|x) = f(x|\theta)f(\theta)$$

$$= \theta(1 - \theta)^2 \cdot 2\theta$$

$$= 2\theta^2(1 - \theta)^2$$

MAP(Maximum A Posterior)

사후 분포를 최대로 하는 파라미터 θ 를 찾기 위해 θ 에 대해 미분해서 0되는 값 찾기

$$\frac{d}{d\theta} f(\theta|x) = \frac{d}{d\theta} [2\theta^2(1-\theta)^2]$$

$$= 4\theta(1-\theta)^2 + 2\theta^2 \cdot 2(1-\theta)(-1)$$

$$= 4\theta(1-\theta)^2 - 4\theta^2(1-\theta)$$

$$4\theta(1-\theta)^2 - 4\theta^2(1-\theta) \equiv 0$$

$$\Leftrightarrow 4\theta(1-\theta)^2 = 4\theta^2(1-\theta)$$

$$\Leftrightarrow 1-\theta = \theta$$

$$\Leftrightarrow \hat{\theta}_{MAP} = \frac{1}{2}$$

감사합니다.

Q & A