

AI/BigData 인텐시브 과정

강사장철원

Section 0

코스소개

DAY1

DAY2

DAY3

DAY4

DAY5

데이터 분석을 위한 기초 수학

데이터 집계 및 시각화

DAY6

DAY7

DAY8

DAY9

DAY10

미니
프로젝트

확률분포, AB테스트

DAY11

DAY12

DAY13

DAY14

DAY15

머신러닝

DAY16

DAY17

DAY18

DAY19

DAY20

딥러닝

파이널 프로젝트

□ 가설 검정 개념

□ 두 집단 차이 검정

□ 세 집단 차이 검정

□ 연관성 검정

가설/검정
↓
비교
측정하여
검정
개/교양이 별
의미

test.

AI/BigData 인텐시브 과정

Section 1. 두 집단 평균 차이 검정

Section 1-1. 가설 검정의 개념

가설 검정의 개념


가설 검정 = '가설'을 '검정'한다

TEST

두 집단 간 차이가 있을까?

가설검정이 무엇인가?

AB 테스트 ⁱⁿ 마케팅 . 실험집단



시험 점수,
소비량,
생산량,
마케팅 효과,
...

두 집단 간 차이가 있을까?

가설설정

= null hypothesis, 평가설

귀무가설
(H₀)

두 집단 평균 생산량 차이 없다.


대립가설
(H₁)

노랑 집단 평균 생산량이
파랑 집단 보다 높다.

= alternative hypothesis, H_a

가설 개를 세우고 둘중에 무엇이 맞는지를 검증하는것

파랑색 집단 vs 노랑색 집단 '생산량' 차이 분석



두 집단 간 차이가 있을까?

표집에서는 차이가 없는것을 원함 → 그래도 H_0 에 차이 없는것 쓰기
→ H_0 를 원하면된다

귀무가설(H_0)

차이가 없거나 영향도 없음

기존에 존재하던 가설

분석가의 주장과 반대 가설

대립가설(H_1)

차이가 있거나 영향도 있음


분석가가 새롭게 제시한 가설

분석가가 채택하고 싶은 가설

- 양측검정 언제쓸까? 데이터 상에서 별표 차이가 안날때.
[방향이 중요하지 않을때 (예) 평균]

양측 검정 vs 단측 검정

파랑색 집단 vs 노랑색 집단
'생산량' 차이 분석



귀무가설
(H0)

두 집단 생산량 차이 없다.

양측 검정

대립가설
(H1)

두 집단 생산량 차이 있다.

$\mu_1 \neq \mu_2$

파랑색 생산량 > 노랑색 생산량

파랑색 생산량 < 노랑색 생산량

방향을 fix스

단측 검정

대립가설
(H1)

노랑 집단 생산량이 파랑 집단 보다 높다.

파랑색 생산량 < 노랑색 생산량

$\mu_1 < \mu_2$

* 데이터가있는데 가설세우는이유? 무슨 알고싶어서.
이데이터는 표본이기때문에

양측 검정 vs 단측 검정

귀무가설
(H0)

두 집단 생산량 차이 없다.

모평균이 같다
 $H0: \mu_1 = \mu_2$

양측 검정

대립가설
(H1)

두 집단 생산량 차이 있다.

모평균이 다르다
 $H1: \mu_1 \neq \mu_2$

파랑색 생산량 > 노랑색 생산량

파랑색 생산량 < 노랑색 생산량

단측 검정

대립가설
(H1)

노랑 집단 생산량이 파랑 집단 보다 높다.

파랑색 생산량 < 노랑색 생산량

실용 예제는 단측검정을 더 많이 씀
 $H1: \mu_1 > \mu_2$

가설 검정 프로세스

(순서기대하기)



H_0 : A와 B가 키가 차이가 없다

H_1 : A가 B보다 키가 크다

→ "데이터보고 가설 세움."

그렇지 않으면 다 돌려버림...

STEP 1

가설을 세운다

STEP 2

기준을 세운다

STEP 3

결론을 내린다

가설 검정 프로세스



가설을 세운다



검정통계량(test statistic)을 구한다



결론을 내린다

가설 검정 프로세스

<순서 기억하기>



가설을 세운다




검정통계량(test statistic)을 구한다



결론을 내린다(p-value)

가설 검정 프로세스

↪ 내 말이 맞을 때까지 (H_0) 반복




AI/BigData 인텐시브 과정


Section 1. 두 집단 평균 차이 검정

Section 1-2. 두 집단 평균 차이 검정

두 집단 평균 차이 검정




두 집단 평균 차이 검정



모집단 : 관심대상 전체 집합

표본 : 모집단의 부분 집합


두 집단 평균 차이 검정





(키가 같다고 표현하면 안됨)

H_0 : 파란색과 빨간색의 키의 차이가 없다. (이렇게 표현해야 함)



차이가 난다? (단측) H_1 : 파란색이 빨간색보다 키가 크다



차이가 난다?



검정 통계량의 개념



$$175 - 174.8 = 0.2$$

별 차이 안나네

검정통계량 개념


기준이 있다

차이 많이 나네!

$$175 - 120 = 55$$

검정 통계량의 개념


여러명일 경우 1명씩 대표할 수 없으니



각 집단의 대표값 필요!


평균, 분산 (표준차)

분산의 개념



평균이 같아도 분산이 다른 경우

두 집단의 성격 다름



평균: 170 cm

분산: 1




평균: 170 cm

분산: 100

평균 구하기



170cm



180cm




160cm

파랑색 그룹 평균

$$= \frac{170+180+160}{3} = 170$$

분산 구하기



170cm 180cm 160cm

평균: 170cm

파랑색 그룹 분산


$$= \frac{\text{편차 제곱의 합}}{n - 1}$$

$$= \frac{(\text{데이터 값} - \text{평균})^2 + (180 - 170)^2 + (160 - 170)^2}{3 - 1}$$

$$= \frac{0 + 100 + 100}{2} = 100$$

가설 검정

데이터 평균을 위해서 살펴보기




평균:173 cm



평균:170 cm

실무에서 단측 검정을 주로 사용하는 이유



귀무가설
(H0)

두 집단 평균 키 차이 없다.

양측 검정

대립가설
(H1)

두 집단 평균 키 차이 있다.

단측 검정

데이터를 보고
이렇게 가설 세움

대립가설
(H1)

파란색 집단 평균 키가 노란색 집단 보다 크다.

표본 평균을 통해 어느 쪽이 더 큰지 짐작 할 수 있다.

p-value란?

내가 가진 데이터가 얼마나 우연히 나왔느냐

(내가 가진 데이터보다)

- 귀무가설(H_0)이 참이라고 했을 때, 표본 데이터 이상으로 극단적인 데이터가 수집될 확률
- P-value가 낮을 수록, 대립가설(H_1) 채택
- 통상적으로 p-value < 0.05 면 대립가설(H_1) 채택
- 이때 0.05를 유의 수준(α)이라고 하며 대개 0.05 또는 0.01 중 선택

우리가 원하는 건 H_1 . P-value가 작을수록 좋음. (예가 없을수록)

더 엄격해짐.


유의수준?

= 1종 오류

- α 수준을 정했더라도 상한치는 20%인데 따라 다르지만, 보통 1종 오류를 생각해보는.

		예측	
		H0 채택	H1 채택
실제 <u> </u>	H0가 참	정답	(유의수준) 1종 오류 = α (Type 1 Error)
	H1이 참	2종 오류 = β (Type 2 Error)	정답

p-value란?



임의로 뽑은 표본의 평균 키가
190



그렇다면 실제 키의 분포는?


p-value란?

임의로 뽑은 표본의 키가 190cm 이므로 대립가설 설정


- 귀무가설(H_0): 남자들의 평균 키는 170cm이다
- 대립가설(H_1): 남자들의 평균 키는 170cm보다 크다

p-value란?


- 귀무가설(H_0): 남자들의 평균 키는 170cm이다
- 대립가설(H_1): 남자들의 평균 키는 170cm보다 크다




p-value란?



p-value란?




p-value란?



귀무가설이 맞다는 전제 하의 분포

두 집단 평균 차이 검정


100명



평균: 173 cm

분산: 300

100명



평균: 170 cm

분산: 200

z 통계량 구하기

* 검정통계량 구하는 방법이 굉장히 다양함.

- z값, t값, F값, χ^2 값 ...

100명



평균: 173 cm
분산: 300

100명



평균: 170 cm
분산: 200

검정통계량 (z값)

$$Z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

• 매개변수
• z는 확률변수

• $z \sim N(0,1)$
표준정규분포

$$= \frac{173 - 170}{\sqrt{\frac{300}{100} + \frac{200}{100}}}$$

$$= \frac{3}{2.23}$$

$$= 1.34 \text{ (1.34)} \text{ (1.34)}$$



/ /

H_0 : 파란색과 노란색의 평균 차이가 없다.


H_1 : 파란색의 평균값이 노란색보다 크다.

p-value

p-value를 구하려면

 H_0 에 대한 그림 그려야 함. H_0 기각 = H_1 채택 H_0 가 맞다는 말이면 $Z \sim N(0, 1)$

* H_0 채택 - H_0 를 기각할 수 없다
 H_1 채택 - H_0 를 기각할 수 있다



p-value < 0.05 이면 귀무가설 기각 = H_1 채택

두 집단 평균 차이 검정

In [14]: 1 df.head(5)

Out[14]:

	GENDER	TEAM	EDUCATION	TRAINING	ACHIEVEMENT	ABILITY	ATTITUDE
0	female	B	bachelor's degree	none	72	72	74
1	female	C	some college	completed	69	90	88
2	female	B	master's degree	none	90	95	93
3	male	A	associate's degree	none	47	57	44
4	male	C	some college	none	76	78	75

In [16]: 1 df['TEAM'].unique()


Out[16]: array(['B', 'C', 'A', 'D', 'E'], dtype=object)

In [17]: 1 df_a = df[df['TEAM']=='A']
2 df_b = df[df['TEAM']=='B']
3 df_c = df[df['TEAM']=='C']
4 df_d = df[df['TEAM']=='D']
5 df_e = df[df['TEAM']=='E']

In [19]: 1 df_a_ach = df_a['ACHIEVEMENT']
2 df_b_ach = df_b['ACHIEVEMENT']
3 df_c_ach = df_c['ACHIEVEMENT']
4 df_d_ach = df_d['ACHIEVEMENT']
5 df_e_ach = df_e['ACHIEVEMENT']


*검정 시에는
series 활용 필요

두 집단 평균 차이 검정



두 집단 평균 차이 검정

근검정을 하려면?
* 각집단이 모두
정규성을 가질 때
⇒ 정규성 검정이 필요



두 집단 평균 차이 검정


```
In [20]: 1 df_a_mean = np.mean(df_a_ach)
          2 print(df_a_mean)
```

61.62921348314607


```
In [21]: 1 df_b_mean = np.mean(df_b_ach)
          2 print(df_b_mean)
```

63.45263157894737

$df_b_mean > df_a_mean$



두 집단 평균 차이 검정




두 집단 평균 차이 검정

H0: 팀 B의 평균 성과 점수와 팀 A의 평균 성과 점수는 차이가 없다.

H1: 팀 B의 평균 성과 점수가 팀 A의 평균 성과 점수보다 크다

○ 파이선형성 전체로 당해는거 14형에나올듯 22

두 집단 평균 차이 검정



정규성 검정 -> 샤피로 윌크 검정

독집단 모두 정규성검정 필요

```
1 test_stat, p = sp.stats.shapiro(df_a_ach)
2 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

검정통계량: 0.9917356967926025, p-value: 0.8545120358467102

```
4 test_stat, p = sp.stats.shapiro(df_b_ach)
5 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

검정통계량: 0.980807363986969, p-value: 0.010394957847893238

H0: 정규 분포를 따른다

H1: 정규 분포를 따르지 않는다.

H0: 정규 분포를 따른다

H1: 정규 분포를 따르지 않는다.


↓

해설이 명확하지 않기 때문에


정규성 만족하지 않는다고 판단

→ 원변인 원상대로 가야함.

두 집단 평균 차이 검정



z 분포와 t 분포의 차이



두 집단 평균 차이 검정

H0: 팀 B의 평균 성과 점수와 팀 A의 평균 성과 점수는 차이가 없다.

H1: 팀 B의 평균 성과 점수가 팀 A의 평균 성과 점수보다 크다

z-test

Python 함수가 없어서 손으로 계산 하나하나 해야함...

$$Z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

2분간 쓰는 이유
특정 데이터 수 범어가면
6에 수렴하는 성질 있음

$$= \frac{63.45 - 61.62}{\sqrt{\frac{208}{89} + \frac{238}{190}}} = 0.96$$

큰거에서 작은거 빼고 + 부호.
반대로 안되는건 아니지만 불편

<파이썬 함수 사용 예시 나열>

In [20]:

```
1 df_a_mean = np.mean(df_a_ach)
2 print(df_a_mean)
```

61.62921348314607

In [21]:

```
1 df_b_mean = np.mean(df_b_ach)
2 print(df_b_mean)
```

63.45263157894737

In [22]:

```
1 df_a_var = np.var(df_a_ach)
2 print(df_a_var)
```

208.54791061734628

In [24]:

```
1 df_b_var = np.var(df_b_ach)
2 print(df_b_var)
```

238.00565096952909

In [25]:

```
1 n1 = len(df_a_ach)
2 print(n1)
```

89

In [26]:

```
1 n2 = len(df_b_ach)
2 print(n2)
```

190

z-test

```
In [27]: 1 s = ((df_a_var/n1)+(df_b_var/n2))**0.5  
        2 print(s)
```

1.8962848603648552

```
In [28]: 1 z_value = (df_b_mean - df_a_mean)/s  
        2 print(z_value)
```

0.9615739353898897

$$Z = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} = \frac{63.45 - 61.62}{1.89} = 0.96$$

n_1, n_2 커지면 $\frac{\sigma^2}{n} = 0$ 가 됨.

→ p-value가 0


∴ 데이터가 많아지면 p-value가 0에 수렴하는게 문제

데이터 $n \uparrow$ - p-value 작아지는 문제 해결.

해결방법.

① 새로운 기준 정하기 . 0.05 크기점이 안되므로

② 데이터 샘플링해서 가설검정 100번 실행



z-test

In [31]:

```



1 z_dist = sp.stats.norm(0, 1)
2 p_value = 1 - z_dist.cdf(z_value)
3 print(p_value)

```

0.16813183477339466

귀무가설을
거부할수없음

이 z-value에서
부터 cdf값




cdf = 누적 확률 분포 함수


$$p\text{-value} = 1 - \text{cdf}(z\text{-value})$$

$$= 1 - P(Z \leq z\text{-value})$$

두 집단 평균 차이 검정



두 집단 평균 차이 검정



t test

ind = independent
독립표본 t-검정. 두 표본을 독립이라고 보는 것.

→ dependent한 t-test도 있음 (EX) 요양원 생활
(paired t-test) 전발 파문 테스트

평균값이 큰 것을 앞에 둠

H₁ 설정.

In [20]:


```
1 test_stat, p = sp.stats.ttest_ind(df_b_ach, df_a_ach, alternative='greater')
2 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

B형 > A형

two-sided

less

greater



검정통계량: 0.9355076279747488, p-value: 0.17517079808299785

z test vs t test

In [31]:

```
1 z_dist = sp.stats.norm(0, 1)
2 p_value = 1 - z_dist.cdf(z_value)
3 print(p_value)
```

0.16813183477339466

z test

In [20]:


```
1 test_stat, p = sp.stats.ttest_ind(df_b_ach, df_a_ach, alternative='greater')
2 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

검정통계량: 0.9355076279747488, p-value: 0.17517079808299785


t test

z 분포와 t 분포의 차이

검정: z분포
빨강: t분포



두 집단 평균 차이 검정



두 집단 평균 차이 검정

H0: 팀 B의 평균 성과 점수와 팀 A의 평균 성과 점수는 차이가 없다.


H1: 팀 B의 평균 성과 점수가 팀 A의 평균 성과 점수보다 크다

p-value > 0.05 이므로, H0 채택

p-value > 0.05 이므로, H0 채택.

즉, 팀 B의 평균 성과 점수와 팀 A의 평균 성과 점수는 차이가 없다.

두 집단 평균 차이 검정



2. t검정은 '분포'를 사용함

윌콕슨 순위합 검정 ^{test} $\Rightarrow$ 분포를 가정하지 않음. 확률분포를 사용하지 않고 검정

비모수 검정(Non parametric test): 특정 모수를 사용하여 모집단의 분포를 특정 하지 않아도 되는 가설 검정

윌콕슨 순위합 검정
Wilcoxon rank-sum test
상대 rank만



맨-휘트니 U 검정
Mann-Whitney U test

월콕슨 순위합 검정

생산 부품 품질 점수

설비 A	67	73	67	69	58	66	71	63
설비 B	59	57	66	55	60	62	61	66

설비 A의 품질이 설비 B의 품질보다 더 좋다고 할 수 있을까?

윌콕슨 순위합 검정

설비	B	B	A	B	B	B	B	A	B	B	A	A	A	A	A	A
데이터	55	57	58	59	60	61	62	63	66	66	66	67	67	69	71	73
순위	1	2	3	4	5	6	7	8	10	10	10	12.5	12.5	14	15	16

- 두 집단의 데이터를 한데 모아 작은 것부터 큰 것 순서(오름차순)로 일렬로 늘어놓은 후 순위 부여

윌콕슨 순위합 검정

설비	B	B	A	B	B	B	B	A	B	B	A	A	A	A	A	A
데이터	55	57	58	59	60	61	62	63	66	66	66	67	67	69	71	73
순위	1	2	3	4	5	6	7	8	10	10	10	12.5	12.5	14	15	16

- 순위가 동일할 경우 해당 순위의 평균값을 구함
- 예를 들어, 66이라는 데이터가 3개 존재하며 해당 순위는 9,10,11이었으므로 평균값인 10 부여
- 예를 들어, 67이라는 데이터가 2개 존재하며 해당 순위는 12, 13이었으므로 평균값인 12.5 부여

윌콕슨 순위합 검정

설비	B	B	A	B	B	B	B	A	B	B	A	A	A	A	A	A
데이터	55	57	58	59	60	61	62	63	66	66	66	67	67	69	71	73
순위	1	2	3	4	5	6	7	8	10	10	10	12.5	12.5	14	15	16

설비 A의 순위합(*rank sum*): $3 + 8 + 10 + 12.5 + 12.5 + 14 + 15 + 16 = 91$

설비 B의 순위합(*rank sum*): $1 + 2 + 4 + 5 + 6 + 7 + 10 + 10 = 45$

따르석이 있는함

$91 > 45$

(중앙값 비교)

윌콕슨 순위합 검정

In [19]:

```
1 test_stat, p = sp.stats.ranksums(df_b_ach, df_a_ach, alternative='greater')  
2 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

검정통계량: 1.35398583683992, p-value: 0.08787044816326

H0: 팀 B의 성과 점수 중앙값과 팀 A의 성과 점수 중앙값은 차이가 없다.







H1: 팀 B의 성과 점수 중앙값은 팀 A의 성과 점수 중앙값보다 크다

AI/BigData 인텐시브 과정


Section 2. 세 집단 평균 차이 검정

Section 2-1. 세 집단 평균 차이 검정


세 집단 평균 차이 검정




총 오차 = 집단 **내** 오차 + 집단 **간** 오차



총 오차 = 집단 내 오차 + 집단 간 오차




집단 내 오차



집단 내 오차 = 집단 내 데이터들의 오차제곱의 합

집단 내 오차 = 각 데이터 값 - 해당 집단 평균

집단 내 오차



160 cm

180 cm

파랑색 집단 평균 키 = 170 cm

파랑색 집단 내 오차

$$\begin{aligned} &= (160 - 170)^2 + (180 - 170)^2 \\ &= 100 + 100 \\ &= 200 \end{aligned}$$

집단 내 오차



170 cm


190 cm

노랑색 집단 평균 키 = 180 cm

노랑색 집단 내 오차

$$\begin{aligned} &= (170 - 180)^2 + (190 - 180)^2 \\ &= 100 + 100 \\ &= 200 \end{aligned}$$

집단 내 오차



150 cm


170 cm

빨강색 집단 평균 키 = 160 cm

빨강색 집단 내 오차

$$\begin{aligned} &= (150 - 160)^2 + (170 - 160)^2 \\ &= 100 + 100 \\ &= 200 \end{aligned}$$


집단 내 오차



160 cm 180 cm
평균 170cm



170 cm 190 cm
평균 180cm



150 cm 170 cm
평균 160cm

집단 내 오차

= 파랑색 집단 내 오차
+ 노랑색 집단 내 오차
+ 빨강색 집단 내 오차

세개 다 더함

$$= 200 + 200 + 200$$

$$= 600$$


집단 간 오차



집단 간 오차 = 집단 간 데이터 평균 오차 제공의 합

집단 간 평균 오차 = 각 집단 평균 - 전체 평균

전체 평균 170



160 cm 180 cm

평균 170cm



170 cm 190 cm


평균 180cm



150 cm 170 cm

평균 160cm

집단 간 오차




160 cm 180 cm

평균 170cm



170 cm 190 cm

평균 180cm



150 cm 170 cm

평균 160cm


집단 간 오차

$$\begin{aligned}
 &= 2 \times (170 - 170)^2 + \\
 &\quad 2 \times (180 - 170)^2 + \\
 &\quad 2 \times (160 - 170)^2 \\
 &= 0 + 200 + 200 \\
 &= 400
 \end{aligned}$$


사람 평균

집단 평균

집단 간 오차 > 집단 내 오차 이면 집단 간 평균 차이 존재



집단 간 오차



집단 내 오차



집단 간 평균 차이가 있다!

집단 간 오차 > 집단 내 오차 이면 집단 간 평균 차이 존재

집단 간 오차

$$\begin{aligned} &= 2 \times (170 - 170)^2 + \\ &\quad 2 \times (180 - 170)^2 + \\ &\quad 2 \times (160 - 170)^2 \\ &= 0 + 200 + 200 \\ &= 400 \end{aligned}$$

집단 내 오차

$$\begin{aligned} &= \text{파랑색 집단 내 오차} \\ &\quad + \text{노랑색 집단 내 오차} \\ &\quad + \text{빨강색 집단 내 오차} \\ &= 200 + 200 + 200 \\ &= 600 \end{aligned}$$



집단 간 평균 차이가 없다!

F-검정(ANOVA검정): F 통계량


$$F \text{ 통계량} = \frac{\text{집단 간 오차} / (\text{집단 개수} - 1)}{\text{집단 내 오차} / (\text{전체 데이터 수} - \text{집단 개수})}$$

스케일 검역할

* 분자가 크면 집단 차이가 큼
→ F통계량은 커져야 함


$$F \text{ 통계량} = \frac{400 / (3 - 1)}{600 / (6 - 3)} = \frac{200}{200} = 1$$

F 분포




$p\text{-value} < 0.05$ 이면 귀무가설 기각


세 집단 평균 차이 검정



세 집단 평균 차이 검정



세 집단 평균 차이 검정



세 집단 평균 차이 검정


H0: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 평균 성과 점수는 차이가 없다.

H1: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 평균 성과 점수는 차이가 있다.

$$\left[\begin{array}{l} H_0: \mu_1 = \mu_2 = \mu_3 \\ H_1: \text{not } H_0 \end{array} \right]$$

세 집단 이상부터는 방향설정이 안됨.
차이있다. 없다.
 $\neq =$

세 집단 평균 차이 검정



정규성 검정

H0: 정규 분포를 따른다

H1: 정규 분포를 따르지 않는다.

정규성 검정


```
1 test_stat, p = sp.stats.shapiro(df_a_ach)
2 print("검정통계량: {}, p-value: {}".format(test_stat, p))
3
4 test_stat, p = sp.stats.shapiro(df_b_ach)
5 print("검정통계량: {}, p-value: {}".format(test_stat, p))
6
7 test_stat, p = sp.stats.shapiro(df_c_ach)
8 print("검정통계량: {}, p-value: {}".format(test_stat, p))
9
10 test_stat, p = sp.stats.shapiro(df_d_ach)
11 print("검정통계량: {}, p-value: {}".format(test_stat, p))
12
13 test_stat, p = sp.stats.shapiro(df_e_ach)
14 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

검정통계량: 0.9917356967926025, p-value: 0.8545120358467102
검정통계량: 0.980807363986969, p-value: 0.010394957847893238
검정통계량: 0.9891074299812317, p-value: 0.017419686540961266
검정통계량: 0.9896668195724487, p-value: 0.05926159396767616
검정통계량: 0.9770452976226807, p-value: 0.01849617063999176

샤피로 윌크 테스트

정규 분포를 따르지 않는다

세 집단 평균 차이 검정



분산 동질성 검정

H0: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 분산이 동일하다.

H1: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 분산이 동일하지 않다.

분산 동질성 검정


```
1 test_stat, p = sp.stats.bartlett(df_a_ach, df_b_ach, df_c_ach, df_d_ach, df_e_ach)
2 print("검정통계량: {}, p-value: {}".format(test_stat, p))
```

검정통계량: 4.075678014368108, p-value: 0.39586081869788264

H0: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 분산이 동일하다.

H1: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 분산이 동일하지 않다.

세 집단 평균 차이 검정



세 집단 평균 차이 검정

subway anova도 있음

```
In [58]: 1 test_stat, p_val = sp.stats.f_oneway(df_a_ach, df_b_ach, df_c_ach, df_d_ach, df_e_ach)
          2 print('검정통계량: ', test_stat)
          3 print('p-value: ', p_val)
```


검정통계량: 14.593885166332635

p-value: 1.3732194030370688e-11 < 0.05

H0: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 평균 성과 점수는 차이가 없다.

H1: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 평균 성과 점수는 차이가 있다.

세 집단 평균 차이 검정



```
In [59]: 1 test_stat, p_val = sp.stats.kruskal(df_a_ach, df_b_ach, df_c_ach, df_d_ach, df_e_ach)
          2 print('검정통계량: ', test_stat)
          3 print('p-value: ', p_val)
```

검정통계량: 57.079329705742886
p-value: 1.1906568165839682e-11

비모수검정은 중앙값을 계산했죠? (평균대신?)

H0: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 성과 점수 중앙값은 차이가 없다.

H1: 팀 A, 팀 B, 팀 C, 팀 D, 팀 E의 성과 점수 중앙값은 차이가 있다.

① 상황에서는 여러집단비교인 ANOVA를 먼저 하고, 같다면 넘어감.

② 다르다면, χ^2 test 수행해서 어떤 집단간에 다른지 봐야함.

AI/BigData 인텐시브 과정

Section 3. 분할표를 활용한 연관성 분석

Section 3-1. 카이제곱 검정

카이제곱검정

→ 연관성을 보는 것

p.s. crosstab 형태.

둘 다 범주형 변수

		폐암 유무		합계
		무	유	
흡연여부	비흡연자	14	2	16
	흡연자	10	9	19
합계		24	11	35

귀무가설(H0) : 흡연여부와 폐암유무는 연관성이 없다.

대립가설(H1) : 흡연여부와 폐암유무는 연관성이 있다.

카이제곱 검정

$$\text{카이제곱 통계량} = \frac{(\text{관측값} - \text{기대값})^2}{\text{기대값}}$$

카이제곱 검정

		폐암 유무		합계
		무	유	
흡연여부	비흡연자	n11	n12	n1+
	흡연자	n21	n22	n2+
합계		n+1	n+2	n++

귀무가설(H_0) : 흡연여부와 폐암유무는 연관성이 없다.

대립가설(H_1) : 흡연여부와 폐암유무는 연관성이 있다.

카이제곱 검정

		폐암 유무		합계
		무	유	
흡연여부	비흡연자	n11	n12	n1+
	흡연자	n21	n22	n2+
합계		n+1	n1+	n++

관측값

카이제곱 검정

		폐암 유무		합계
		무	유	
흡연여부	비흡연자	14	2	16
	흡연자	10	9	19
합계		24	11	35

n_{11} 에 들어올것으로 기대되었던 값.

n_{11} 의 기대값

$$= \frac{16 \times 24}{35} = 10.97$$

관측값에 대한 기댓값

		폐암 유무		합계
		무	유	
흡연여부	비흡연자	14	2	16
	흡연자	10	9	19
합계		24	11	35

n12의 기대값

$$= \frac{16 \times 11}{35} = 5.02$$

n21의 기대값

$$= \frac{19 \times 24}{35} = 13.02$$

n22의 기대값

$$= \frac{19 \times 11}{35} = 5.97$$

카이제곱 통계량

$$\text{카이제곱 통계량} = \frac{(\text{관측값} - \text{기대값})^2}{\text{기대값}}$$

카이제곱 통계량


		폐암 유무		합계
		무	유	
흡연여부	비흡연자	14	2	16
	흡연자	10	9	19
합계		24	11	35

카이제곱 통계량

$$= \frac{(14-10.97)^2}{10.97} + \frac{(2-5.02)^2}{5.02} + \frac{(10-13.02)^2}{13.02} + \frac{(9-5.97)^2}{5.97}$$

$$= 0.83 + 1.81 + 0.70 + 1.53 = 4.87$$

카이제곱 통계량



$p\text{-value} < 0.05$ 이면 귀무가설 기각

카이제곱 검정

H0: 팀 C 여부와 사내 수강 여부에는 연관성이 없다.

H1: 팀 C 여부와 사내 수강 여부에는 연관성이 있다.

카이제곱 검정

카이제곱보기

중. t. ANOVA로 검정하기. (2분 나뉘어서
하연될듯?)

```
In [50]: 1 df['C_OR_NOT'] = np.where(df['TEAM']=='C', 'C', 'not_C')
```

```
In [51]: 1 df.head(5)
```

Out[51]:

	GENDER	TEAM	EDUCATION	TRAINING	ACHIEVEMENT	ABILITY	ATTITUDE	C_OR_NOT
0	female	B	bachelor's degree	none	72	72	74	not_C
1	female	C	some college	completed	69	90	88	C
2	female	B	master's degree	none	90	95	93	not_C
3	male	A	associate's degree	none	47	57	44	not_C
4	male	C	some college	none	76	78	75	C

상관관계보기

```
In [52]: 1 df['TRAINING'].unique()
```

Out[52]: array(['none', 'completed'], dtype=object)

```
In [53]: 1 df['C_OR_NOT'].unique()
```

Out[53]: array(['not_C', 'C'], dtype=object)

카이제곱 검정

In [54]:


```
1 obs = pd.crosstab(df['C_OR_NOT'], df['TRAINING'])  
2 obs
```

→ 순수 crosstab만
고려야함.
다른 옵션 설정 X

Out[54]:

TRAINING		completed	none
C_OR_NOT			
C		117	202
not_C		241	440

분할표 내부 숫자가 너무 작으면(5 미만) 비효율



Fisher's Exact Test

카이제곱 검정

In [39]:

```

1 chi2, p_value, d expected = sp.stats.chi2_contingency(obs)
2 print("H0: 팀C 여부와 사내 교육 수강 여부는 연관성이 없다.")
3 print("H1: 팀C 여부와 사내 교육 수강 여부는 연관성이 있다.")
4 print('검정통계량: ', chi2)
5 print('p-value: ', p_value)
6 print("결론: H0 채택, 팀C 여부와 사내 교육 수강 여부는 연관성이 없다.")

```

H0: 팀C 여부와 사내 교육 수강 여부는 연관성이 없다.

H1: 팀C 여부와 사내 교육 수강 여부는 연관성이 있다.

검정통계량: 0.10576554193252763

p-value: 0.745017489209715

결론: H0 채택, 팀C 여부와 사내 교육 수강 여부는 연관성이 없다.

★
시험문제에서
답안 이렇게
써야함

— 직접으로 쓰지 않기

— print문을으로 작성

감사합니다.

Q & A