

AI/BigData 인텐시브 과정

강사장철원

Section 0

코스소개

DAY1

DAY2

DAY3

DAY4

DAY5

데이터 분석을 위한 기초 수학

데이터 집계 및 시각화

DAY6

DAY7

DAY8

DAY9

DAY10

미니
프로젝트

확률분포, AB테스트

DAY11

DAY12

DAY13

DAY14

DAY15

머신러닝

DAY16

DAY17

DAY18

DAY19

DAY20

딥러닝

파이널 프로젝트

□ 데이터 스케일링

□ 모형 평가

□ 교차 검증



AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-1. 데이터 스케일링

데이터 스케일링

데이터 단위가 다르면 비교가 어렵다



70 kg

데이터 스케일링

데이터 단위가 다르면 비교가 어렵다

키	몸무게
170	70
175	80
180	90

170 > 70 ?

데이터 표준화(standardization)

$$\text{표준화} = \frac{\text{원 데이터} - \text{평균}}{\text{표준편차}}$$



평균 0, 표준편차 1

데이터 표준화(standardization)

키	몸무게
170	70
175	80
180	90

평균 175
표준편차 5

평균 80
표준편차 10

키	몸무게
$\frac{170 - 175}{5} = -1$	$\frac{70 - 80}{10} = -1$
$\frac{175 - 175}{5} = 0$	$\frac{80 - 80}{10} = 0$
$\frac{180 - 175}{5} = 1$	$\frac{90 - 80}{10} = 1$

평균 0
표준편차 1

평균 0
표준편차 1

MinMax 스케일링

$$\text{MinMax 스케일} = \frac{\text{원 데이터} - \min(\text{데이터})}{\max(\text{데이터}) - \min(\text{데이터})}$$



0과 1사이로 데이터 위치

데이터 스케일링

키	몸무게
170	70
175	80
180	90

최대값 180
최소값 170

최대값 90
최소값 70

키	몸무게
$\frac{170-170}{180-170} = 0$	$\frac{70-70}{90-70} = 0$
$\frac{175-170}{180-170} = 0.5$	$\frac{80-70}{90-70} = 0.5$
$\frac{180-170}{180-170} = 1$	$\frac{90-70}{90-70} = 1$

최대값 1
최소값 0

최대값 1
최소값 0

AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-2. 머신러닝 모형 평가


모형 평가

모형이 좋다?/나쁘다?




꽃 분류 모형


환자가 양성인지 음성인지 예측하는 상황



환자가 양성인지 음성인지 예측하는 상황



case 1) 모두 병에 걸렸다고 판정



case 1) 모두 병에 걸렸다고 판정

장점


실제로 병에 걸린
모든 사람들을 치료할 수 있다.

단점

정상인인 사람을 환자로 오인





양성으로 진단(병에 걸렸다고 판정)



음성으로 진단(정상인이라고 판정)



case 2) 모두 음성이라고 판정



case 2) 모두 음성이라고 판정

장점


정상인을 오인하는 경우가 없음

단점


실제 병에 걸린 사람을 치료할 수 없음



양성으로 진단(병에 걸렸다고 판정)



음성으로 진단(정상인이라고 판정)



예측 분류표

		예측	
		양성	음성
실제	양성	정답	오답
	음성	오답	정답

예측 분류표

		예측	
		양성	음성
실제	양성	True Positive	False Negative Type II Error
	음성	False Positive Type I Error	True Negative

예측 분류표

		예측	
		양성	음성
실제	양성	True Positive TP	False Negative FN
	음성	False Positive FP	True Negative TN

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{\text{정답 데이터}}{\text{전체 데이터}}$$

$$\text{에러율(Error rate)} = \frac{FP + FN}{TP + FP + FN + TN} = \frac{\text{오답 데이터}}{\text{전체 데이터}}$$

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{\text{예측양성, 실제양성}}{\text{실제 양성}}$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{\text{예측양성, 실제양성}}{\text{예측 양성}}$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN} = \frac{\text{예측양성, 실제음성}}{\text{실제 음성}}$$

예측 분류표

		예측	
		양성	음성
실제	양성	5 TP	3 FN
	음성	2 FP	10 TN

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{5+10}{5+2+3+10} = \frac{15}{20} = 0.75$$

$$\text{에러율(Error rate)} = \frac{FP + FN}{TP + FP + FN + TN} = \frac{2+3}{5+2+3+10} = \frac{5}{20} = 0.25$$

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{5}{5+3} = \frac{5}{8} = 0.625$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{5}{5+2} = \frac{5}{7} = 0.714$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN} = \frac{2}{10+2} = \frac{2}{12} = 0.167$$

예측 분류표

		예측	
		양성	음성
실제	양성	5 TP	3 FN
	음성	2 FP	10 TN

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{5}{5+3} = \frac{5}{8} = 0.625$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{5}{5+2} = \frac{5}{7} = 0.714$$

$$\text{F1-score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = 2 \times \frac{0.714 \times 0.625}{0.714 + 0.625} = 0.666$$

모형 평가

평균 제곱 오차
(Mean Squared Error)

평균

제곱

오차

$$\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


평균

오차

제곱


모형 평가

실제값 Y_i	예측값 $\hat{Y}_i$
170	171
175	173
180	183



모형 평가

실제값	모형으로 추정한 값
170	171
175	173
180	183



$$\begin{aligned}MSE &= \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \\&= \frac{1}{3} \times [(170 - 171)^2 + (175 - 173)^2 + (180 - 183)^2] \\&= \frac{1}{3} \times [1^2 + 2^2 + 3^2] = \frac{1}{3} \times (1 + 4 + 9) = \frac{1}{3} \times 14 \\&= 4.67\end{aligned}$$

모형 평가

Mean Squared Error

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


Root Mean Squared Error

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$


Mean Absolute Error

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$


오버피팅(overfitting)




오버피팅(overfitting)



오버피팅(overfitting)




오버피팅(overfitting)




모형 일반화 적용이 목적




어느 모형이 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까




언더피팅(underfitting)



언더피팅(underfitting)





언더피팅(underfitting)



AI/BigData 인텐시브 과정

Section 1. 모형 평가


Section 1-3. 교차 검증(cross validation)



Section
교차검증


컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험
1회 기출문제	1회 정답	2회 기출문제	2회 정답	3회 기출문제	3회 정답	4회 기출문제	4회 정답	5회 기출문제	5회 정답
컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험
6회 기출문제	6회 정답	7회 기출문제	7회 정답	8회 기출문제	8회 정답	9회 기출문제	9회 정답	10회 기출문제	10회 정답

교차 검증(cross validation)




교차 검증(cross validation)

모델 학습시 사용했던 데이터는 모델 평가에 사용 불가




교차 검증(cross validation)

트레이닝 데이터 / 테스트 데이터 분리




교차 검증(cross validation)

트레이닝 데이터 / 테스트 데이터 분리




교차 검증(cross validation)

트레이닝 데이터 / 밸리데이션 데이터 / 테스트 데이터 분리




교차 검증(cross validation)


트레이닝 데이터 / 밸리데이션 데이터 / 테스트 데이터 분리



k fold cross validation



교차 검증(cross validation)



감사합니다.

Q & A