

AI/BigData 인텐시브 과정

강사장철원

Section 0

코스소개

DAY1

DAY2

DAY3

DAY4

DAY5

데이터 분석을 위한 기초 수학

데이터 집계 및 시각화

DAY6

DAY7

DAY8

DAY9

DAY10

미니
프로젝트

확률분포, AB테스트

DAY11

DAY12

DAY13

DAY14

DAY15

머신러닝

DAY16

DAY17

DAY18

DAY19

DAY20

딥러닝

파이널 프로젝트

□ 데이터 스케일링

□ 모형 평가

□ 교차 검증



AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-1. 데이터 스케일링

데이터 스케일링

데이터 단위가 다르면 비교가 어렵다



70 kg

데이터 스케일링

데이터 단위가 다르면 비교가 어렵다

키	몸무게
170	70
175	80
180	90

170 > 70 ?

데이터 표준화(standardization)

정규분포에서 봤을 때.

$$\text{표준화} = \frac{\text{원 데이터} - \text{평균}}{\text{표준편차}}$$

→ 평균이냐 표준화가 가능.



평균 0, 표준편차 1

$-\infty < \text{표준화값} < +\infty$

데이터 표준화(standardization)

→ 치에 어떻게 넣어야 할지

키	몸무게
170	70
175	80
180	90

평균 175
표준편차 5

평균 80
표준편차 10

★ ML 학습시킬 때 이 데이터를 넣어야 함
예측할 때 test 데이터를 넣을 때
표준화한 것에 넣어야 함
같은 숫자가 됨

키	몸무게
$\frac{170 - 175}{5} = -1$	$\frac{70 - 80}{10} = -1$
$\frac{175 - 175}{5} = 0$	$\frac{80 - 80}{10} = 0$
$\frac{180 - 175}{5} = 1$	$\frac{90 - 80}{10} = 1$

변수별로 나눠야 함

평균 0
표준편차 1

평균 0
표준편차 1

MinMax 스케일링

↳ **outlier가 있는 경우에는**
이거 안쓰는게 좋음

Q. 표준화 VS minmax 무엇을 쓰게 좋을지?

→ 그치고그치다름. 특징을 봐야함.

$-\infty < \text{표준화값} < \infty$. $0 < \text{minmax 스케일링값} < 1$
→ **나눌수있는 값의 제한이 있냐 없냐의 특징**

$$\text{MinMax 스케일} = \frac{\text{원 데이터} - \min(\text{데이터})}{\max(\text{데이터}) - \min(\text{데이터})}$$



0과 1사이로 데이터 위치 (∵ 학습아님. 주의 명)
붙어야(+).

표준화는 음수일 수 있음.

데이터 스케일링

키	몸무게
170	70
175	80
180	90

변환
→

키	몸무게
$\frac{170-170}{180-170} = 0$	$\frac{70-70}{90-70} = 0$
$\frac{175-170}{180-170} = 0.5$	$\frac{80-70}{90-70} = 0.5$
$\frac{180-170}{180-170} = 1$	$\frac{90-70}{90-70} = 1$

feature range
범위

최대값 180
최소값 170

최대값 90
최소값 70

최대값 1
최소값 0

최대값 1
최소값 0

• 표준화 (standardization)

1-평균

표준편차

→ 평균 0. 표준편차 1.

* standardization

평균 0. 분산 1.

normalization ?

regularization ? (정제화)

: 모든 용어가 출현하는지. 용어출현이 힘들다...

* normalization

차이점: $\frac{a}{\|a\|}$

벡터를 norm으로 나눠
길이가 1이 됨.

regularization

다항식에서 제약항 넣는 것을
regularization 이라고 부름

AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-2. 머신러닝 모형 평가


모형 평가

모형이 좋다?/나쁘다?




꽃 분류 모형

환자가 양성인지 음성인지 예측하는 상황





환자가 양성인지 음성인지 예측하는 상황




case 1) 모두 병에 걸렸다고 판정

병에 걸린 모든 사람 치료가
완치율 100%.
그 인력이 가난한가? 아니.

검사 전



양성으로 진단(병에 걸렸다고 판정)



음성으로 진단(정상인이라고 판정)



case 1) 모두 병에 걸렸다고 판정

장점


실제로 병에 걸린
모든 사람들을 치료할 수 있다.

단점

정상인인 사람을 환자로 오인



양성으로 진단(병에 걸렸다고 판정)





음성으로 진단(정상인이라고 판정)



case 2) 모두 음성이라고 판정

과잉치로이.

극신뢰가가능가? 아님.



case 2) 모두 음성이라고 판정

내가 어떤지표를 정해놔야에 따라 방향이 달라질
(x) 완치율 vs 사망치료를.


장점

정상인을 오인하는 경우가 없음

단점

실제 병에 걸린 사람을 치료할 수 없음

양성으로 진단(병에 걸렸다고 판정)



음성으로 진단(정상인이라고 판정)

예측 분류표

		예측	
		양성	음성
실제	양성	정답	오답
	음성	오답	정답

예측 분류표

		예측	
		양성	음성
실제	양성	정답 True Positive 양성예측	오답 False Negative Type II Error
	음성	False Positive Type I Error 양성 음성예측	True Negative 음성예측

예측 분류표

		예측	
		양성	음성
실제	양성	True Positive TP	False Negative FN
	음성	False Positive FP	True Negative TN

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{\text{정답 데이터}}{\text{전체 데이터}}$$

$$\text{에러율(Error rate)} = \frac{FP + FN}{TP + FP + FN + TN} = \frac{\text{오답 데이터}}{\text{전체 데이터}}$$

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{\text{예측양성, 실제양성}}{\text{실제 양성}} = \frac{\text{맞춘거}}{\text{실제양성}}$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{\text{예측양성, 실제양성}}{\text{예측 양성}} = \frac{\text{맞춘거}}{\text{예측양성}}$$

$$\text{False Positive Rate} = \frac{FP}{FP + TN} = \frac{\text{예측양성, 실제음성}}{\text{실제 음성}} = \frac{\text{잘못 예측한 사람}}{\text{정상인}}$$

정확도 + 에러율
= 1

예측 분류표

		예측	
		양성	음성
실제	양성	5 TP	3 FN
	음성	2 FP	10 TN

무엇을 써야 할까?

정확도라는 말보다는 Accuracy라는 표현 쓰자.

①

$$\text{정확도(Accuracy)} = \frac{TP + TN}{TP + FP + FN + TN} = \frac{5+10}{5+2+3+10} = \frac{15}{20} = 0.75$$

②

$$\text{에러율(Error rate)} = \frac{FP + FN}{TP + FP + FN + TN} = \frac{2+3}{5+2+3+10} = \frac{5}{20} = 0.25$$

③

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{5}{5+3} = \frac{5}{8} = 0.625$$

④

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{5}{5+2} = \frac{5}{7} = 0.714$$

⑤

$$\text{False Positive Rate} = \frac{FP}{FP + TN} = \frac{2}{10+2} = \frac{2}{12} = 0.167$$

실제

예측

	1	0
1	1	2
0	3	94

$$\text{Accuracy} = \frac{95}{100} = 0.95$$

$$\text{Recall} = \frac{1}{1+2} = \frac{1}{3} = 0.33$$

$$\text{Precision} = \frac{1}{1+3} = \frac{1}{4} = 0.25$$

⇒ Accuracy를 쓰면 문제점. 성능이 높아짐.

imbalanced data임. class 0인 경우가 많음. 1은 적음.

전부가 0으로 예측해도 Accuracy가 높다. → precision, Recall을 봐야함.

- 머신러닝에서는 이러한 평가기준이 있음.

예측 분류표

		예측	
		양성	음성
실제	양성	5 TP	3 FN
	음성	2 FP	10 TN

$$\text{민감도(Sensitivity, Recall)} = \frac{TP}{TP + FN} = \frac{5}{5+3} = \frac{5}{8} = 0.625$$

$$\text{정밀도(Precision)} = \frac{TP}{TP + FP} = \frac{5}{5+2} = \frac{5}{7} = 0.714$$

$$\text{F1-score} = 2 \times \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}} = 2 \times \frac{0.714 \times 0.625}{0.714 + 0.625} = 0.666$$

모형 평가

* 예측용제의 모형평가

평균 제곱 오차
(Mean Squared Error)

평균

제곱

오차

$$\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$


평균

오차

제곱

모형 평가

실제값 Y_i	예측값 $\hat{Y}_i$
170	171
175	173
180	183




모델 평가

실제값	모델로 추정한 값
170	171
175	173
180	183

target은 스케일링 안함. $\rightarrow$ MSE 값이 엄청 커질 수 있음 (실전에서...)
(feature만함)

$$\begin{aligned}
 MSE &= \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 \\
 &= \frac{1}{3} \times [(170 - 171)^2 + (175 - 173)^2 + (180 - 183)^2] \\
 &= \frac{1}{3} \times [1^2 + 2^2 + 3^2] = \frac{1}{3} \times (1 + 4 + 9) = \frac{1}{3} \times 14
 \end{aligned}$$



$= 4.67 \rightarrow$ 잘 맞았는지 느낌이...

*상대적으로 MSE가 작은 모델 선택.

모델 평가

Mean Squared Error

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Root Mean Squared Error

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$

Mean Absolute Error


$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

feature의 단위변환을 위해
필요함.


정수값이 정수값과 비교 가능

오버피팅(overfitting) (과적합)

→ 아직까지 완전한 해결 되지 않음..




오버피팅(overfitting)




오버피팅(overfitting)

general화



오버피팅(overfitting)

MSE는 낮을수록




모형 일반화 적용이 목적


데이터가 바뀌어도 잘 맞고 싶음




어느 모형이 우수할까



어느 모형이 더 우수할까




어느 모형이 더 우수할까




어느 모형이 더 우수할까


↪ 새로운 데이터에 대해 MSE가 엄청 커짐




어느 모형이 더 우수할까



언더피팅(underfitting)




언더피팅(underfitting)



언더피팅(underfitting)

underfitting과 overfitting이 더 심한 문제
 ↳ 여기서 2번 더 잘해보면 됨
 ↳ 학습이 잘 된건지 아닌지 파악하기가 힘들고





AI/BigData 인텐시브 과정

Section 1. 모형 평가

Section 1-3. 교차 검증(cross validation)

→ overfitting 해결을 위한 방법.




Section
교차검증

컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험
1회 기출문제	1회 정답	2회 기출문제	2회 정답	3회 기출문제	3회 정답	4회 기출문제	4회 정답	5회 기출문제	5회 정답
컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험	컴퓨터 활용 능력 1급 1회 필기 시험
6회 기출문제	6회 정답	7회 기출문제	7회 정답	8회 기출문제	8회 정답	9회 기출문제	9회 정답	10회 기출문제	10회 정답


이걸 배틀고 끝은 8회까지만 한다.

교차 검증(cross validation)




교차 검증(cross validation)

모형 학습시 사용했던 데이터는 모형 평가에 사용 불가



교차 검증(cross validation)

트레이닝 데이터 / 테스트 데이터 분리 8:2 ~ 9:3으로 나눔 (보통)
학습용 새로운



교차 검증(cross validation)

트레이닝 데이터 / 테스트 데이터 분리

알고리즘 A $\Rightarrow$ 90%

2 B $\Rightarrow$ 95%


3 C $\Rightarrow$ 91%

test data가 고른것.

test data가 바뀌면
언제 알거질 수있음


test data 기준,

validation
data 활용



교차 검증(cross validation)

트레이닝 데이터 / **밸리데이션** 데이터 / 테스트 데이터 분리



Train

Validation

Test

① | ② | ③ val → 90%.


① | ② val | ③ → 92%.

① val | | | → 91%.

91%.


교차 검증(cross validation)

트레이닝 데이터 / 밸리데이션 데이터 / 테스트 데이터 분리




k fold cross validation

k등분해서 n번 돌리기



교차 검증(cross validation)



감사합니다.

— 데이터가 너무 소중할 경우 validation 쓸쓸
(적은 경우)

— 데이터 분할을 하면 Full rank가 개선되?

— 시계열에서는 어떻게 데이터 분리?
→ 순서대로 잘라야 한다.

Q & A